Conocimiento oculto en el cambio climático: modelos supervisados, clustering y análisis de comentarios de YouTube en Orange Data Mining

Ana María Cortés Prieto

Michael Mateo Melgarejo Uribe

Andrés Pineda

Ingeniería en sistemas y computación

Universidad de Cundinamarca – Extensión Chía

Minería de Datos

Edison Gustavo Cañon Varela

Noviembre de 2026

Enlaces de entrega

La entrega de esta etapa se compone de un único informe en PDF que contiene los enlaces a los demás productos y todos los enlaces son públicos y se verificaron antes de la entrega.

Tabla 1

Enlaces de acceso a los productos entregados

Producto	**Enlace**
Repositorio del proyecto	https://github.com/veels3122/ClimaTec
Aplicación Flask publicada	https://climatec-ctrm.onrender.com
Sección «Conocimiento Oculto»	https://climatec-ctrm.onrender.com/etapa-6/contexto-y-preguntas
Video de sustentación	[ENLACE DEL VIDEO]
Flujos de Orange	climate-mining-app/data/etapa6/*.ows (en el repositorio)

Nota. La clave de la API de YouTube no se publica en ningún producto.

Introducción

ClimaTec analiza la relación entre las tendencias recientes del cambio climático (emisiones de CO2 y gases de efecto invernadero, concentración atmosférica y anomalías de temperatura) y los eventos externos, a escala global y regional (Sudamérica) y nacional (Colombia) entre 2020 y 2026.

Las etapas 4 y 5 describieron qué pasa: quién emite más, cómo cambia en el tiempo y cómo se reparte por región, primero por dimensiones y después con un modelo estrella y operaciones OLAP y ese conocimiento es descriptivo: muestra el nivel de emisión de cada país y pero no explica qué lo determina ni qué países se parecen entre sí por razones que no son geográficas.

Esta etapa busca el **conocimiento oculto**, es decir, lo que no se ve a simple vista y con Orange Data Mining se entrenan tres modelos supervisados para saber qué combinación de rasgos explica el nivel de emisión de un país y se agrupan los países con k-Means para descubrir perfiles que cruzan continentes y se analizan comentarios extraídos con la API de YouTube para conocer qué piensa el público sobre el problema y contrastarlo con los datos.

Objetivos

Objetivo general

Descubrir patrones, relaciones y comportamientos que profundicen la comprensión del problema del proyecto mediante modelos de aprendizaje supervisado y no supervisado en Orange Data Mining, y complementar los hallazgos con el análisis de comentarios extraídos con la API de YouTube.

Objetivos específicos

1. Implementar, evaluar y comparar tres modelos supervisados que clasifiquen el nivel de emisión de CO2 per cápita de cada país, y seleccionar el más adecuado.

2. Agrupar a los países según su perfil energético y emisor con k-Means, justificar el número de grupos y caracterizar cada grupo.

3. Extraer, limpiar y analizar en Orange comentarios de YouTube sobre el cambio climático para identificar temas, términos relevantes y sentimiento y agrupaciones.

4. Integrar los resultados de las tres secciones en conclusiones que distingan la evidencia de las hipótesis.

Preguntas de análisis

Tabla 2

Preguntas que guían la etapa

Sección	Pregunta	Técnica en Orange
Supervisado	¿Se puede predecir si un país es emisor Bajo, Medio o Alto de CO2 per cápita a partir de su perfil energético y de sus emisiones de gases distintos al CO2?	Árbol de decisión, Random Forest y regresión logística; Test and Score
Clustering	¿Qué perfiles energético-emisores comparten los países, más allá de su nivel de CO2 per cápita?	k-Means (k = 2 a 8) con silueta
Comentarios	¿Qué temas, opiniones y sentimientos expresa el público sobre el cambio climático, y coinciden con lo que muestran los datos?	Corpus, Preprocess Text, Bag of Words, LDA, Sentiment Analysis y Hierarchical Clustering

Las tres preguntas responden a la pregunta principal del proyecto desde ángulos distintos y el modelo supervisado explica por qué un país emite lo que emite y el clustering ubica a Colombia junto a países con un perfil parecido y no solo junto a sus vecinos y los comentarios agregan la percepción del público, que los datos numéricos no contienen.

Datos y transformaciones

Unidad de análisis

Se usa el conjunto limpio de las etapas 2 y 3 (`clima_limpio.csv`, 21.369 observaciones, 24 indicadores y 231 países) y la región de cada país (`dim_pais_region.csv`) y ese conjunto está en formato largo y con una fila por indicador y país y fecha.

Para los modelos se pivotó a **una fila por país** con el promedio 2020-2024 de cada indicador y 2025 y 2026 se dejan fuera porque casi no tienen datos nacionales y no se usó la unidad país-año porque, si el mismo país aparece cinco veces, la validación cruzada pone años del mismo país en entrenamiento y en prueba: el modelo reconocería al país en lugar de aprender el patrón y las métricas saldrían infladas.

El script `scripts/conocimiento_oculto.py` genera de forma reproducible `supervisado_paises.csv` y `clustering_paises.csv`, con encabezados que Orange interpreta directamente (`cD#` objetivo, `C#` numérica y `D#` categórica y `m#` meta).

Tabla 3

Trazabilidad de la depuración

Paso de depuración	Países
Entidades nacionales en el conjunto limpio	231
− Sin CO2 per cápita (sin objetivo)	18
− Con menos de 4 de 6 predictores	9
Archivo supervisado	204
Archivo de clustering (sin faltantes)	193

Nota. Faltantes que Orange imputa dentro de cada pliegue con el promedio: electricidad per cápita (2), intensidad de la red (3), metano per cápita (8) y óxido nitroso per cápita (8).

Variables y prevención de fuga de información

Tabla 4

Variables derivadas para los modelos

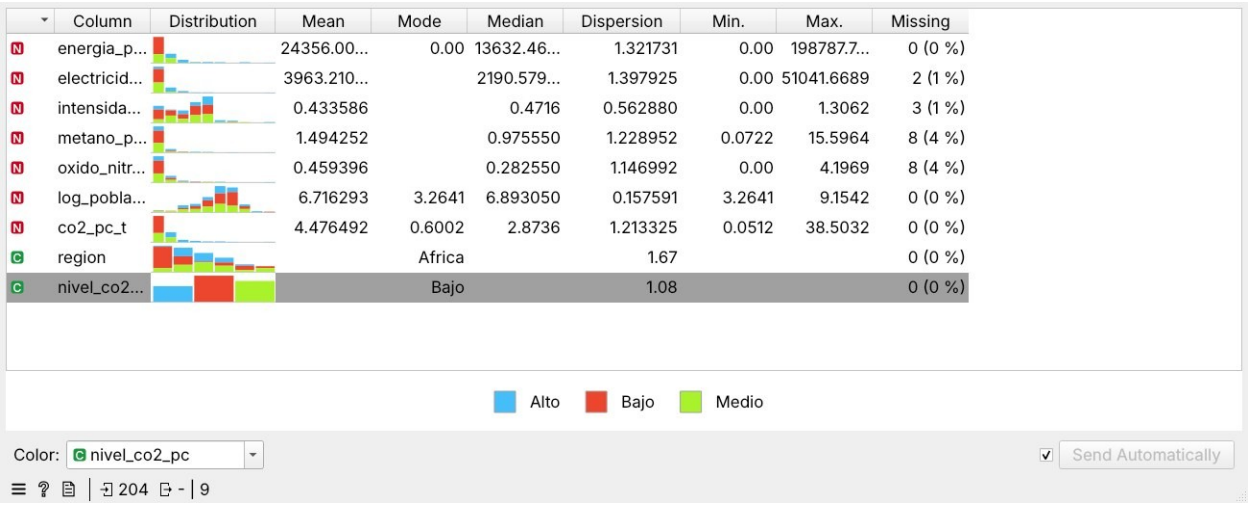
Variable	Cálculo	Uso
`energia_pc_kwh`	Consumo de energía per cápita (OWID)	Supervisado; clustering (log10)

Variable	Cálculo	Uso
`electricidad_pc_kwh`	Generación eléctrica (TWh) × 10^9 / población	Supervisado; clustering (log10)
`intensidad_red_tco2e_mwh`	GEI del sector eléctrico / generación	Supervisado; clustering
`metano_pc_tco2e`	Metano × 10^6 / población	Supervisado; clustering (log10)
`oxido_nitroso_pc_tco2e`	Óxido nitroso × 10^6 / población	Supervisado; clustering (log10)
`log_poblacion`	log10(población)	Supervisado
`region`	Continente (`dim_pais_region.csv`)	Supervisado; descripción
`nivel_co2_pc`	Bajo < 2 t · Medio 2–6 t · Alto ≥ 6 t	Objetivo; solo descripción en clustering

Se excluyeron todas las variables que contienen el CO2 o se calculan con él, porque no estarían disponibles al hacer una predicción real sin conocer la respuesta: emisiones de CO2 total y por combustible, CO2 acumulado y variación anual de CO2 y contribución del CO2 y los GEI a la temperatura y GEI total y per cápita y la imputación y la estandarización se configuran como preprocesadores del modelo y de modo que Orange las ajusta dentro de cada pliegue de la validación cruzada.

Figura 1

Estadísticas de las variables del archivo supervisado (Feature Statistics)



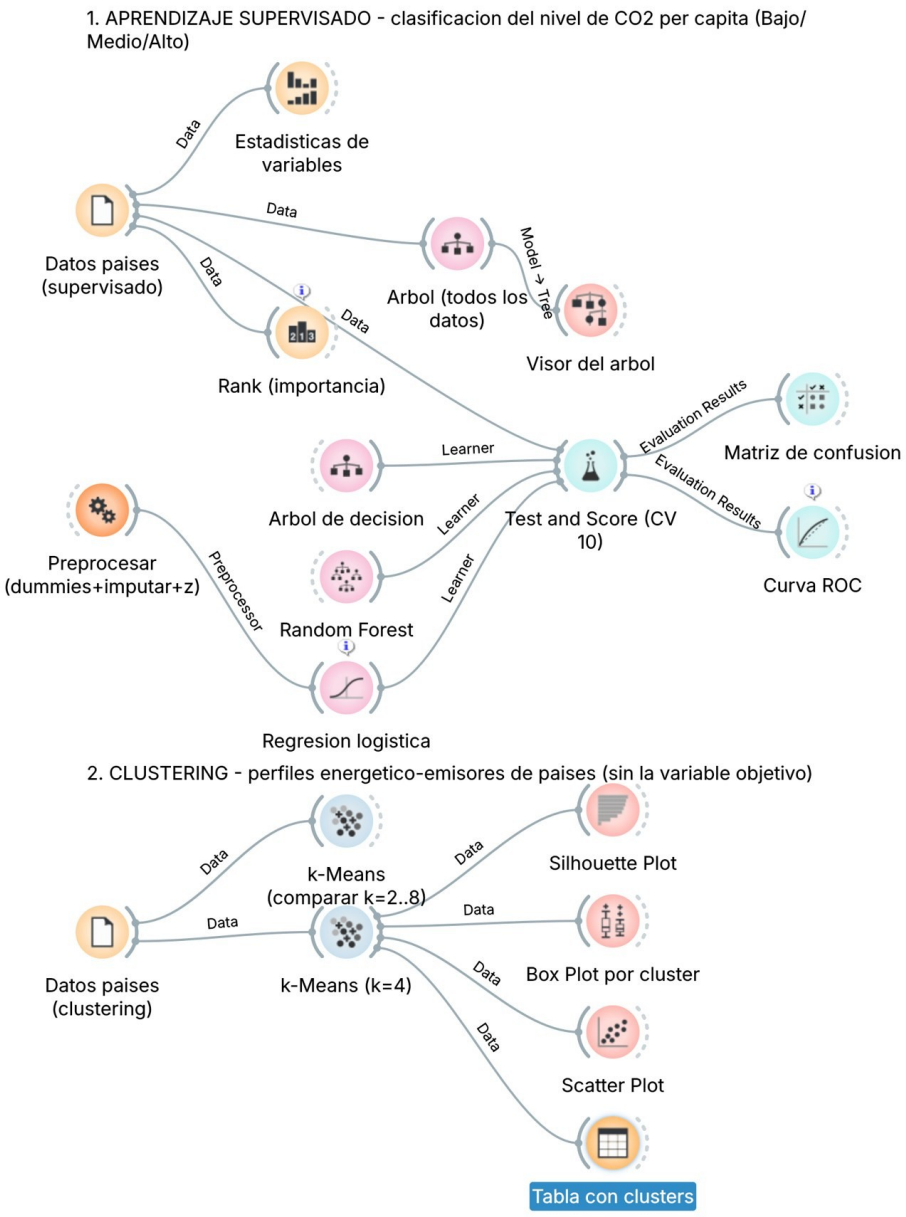
Nota. Captura del flujo en Orange Data Mining.

Las variables tienen una asimetría fuerte: unos pocos petroestados e islas pequeñas tienen valores diez o cien veces mayores que la mediana, por ejemplo una energía per cápita de 199.000 kWh frente a una mediana cercana a 14.000 y sin transformar, k-Means con k = 2 solo separaba 20 países extremos de los otros 173 y por eso y para el clustering se aplicó log10 a energía electricidad y metano y óxido nitroso y después se estandarizó con *Normalize columns* y los árboles no necesitan esa transformación y la regresión logística estandariza en su preprocesador.

Flujos de Orange

Figura 2

Flujo etapa6_conocimiento_oculto.ows: aprendizaje supervisado (arriba) y clustering (abajo)



Nota. Captura del flujo en Orange Data Mining.

Supervisado: *File* carga `supervisado_paises.csv` y alimenta *Feature Statistics*, *Rank*, *Test and Score* y un árbol entrenado con todos los datos y que se usa solo para leer las reglas en *Tree Viewer* y los tres learners se conectan a *Test and Score* y que envía sus resultados a *Confusion Matrix* y *ROC Analysis*.

Preprocesador: *Preprocess* (Continuize → Impute → Normalize) entra en la regresión logística y al conectar un preprocesador, Orange deja de aplicar los pasos por defecto del learner: con solo *Normalize* el modelo fallaba por la variable categórica `region`, así que se agregaron Continuize e Impute.

Clustering: *File* carga `clustering_paises.csv` y un k-Means compara k = 2 a 8 y otro fija k = 4 y su salida, con la columna *Cluster*, va a *Silhouette Plot* y *Box Plot* y *Scatter Plot* y *Data Table* y los archivos `.ows` guardan rutas relativas a su carpeta y así que se abren desde `data/etapa6/` y encuentran los CSV.

Tabla 5

Widgets, parámetros y conexiones del flujo de modelos

Widget	Parámetros	Conexión
File (supervisado)	Objetivo `nivel_co2_pc`; metas país, ISO3 y CO2	Data → Feature Statistics, Rank, Test and Score, Tree
Preprocess	Continuize (una columna por valor), Impute (promedio), Normalize ($\mu = 0$, $\sigma^2 = 1$)	Preprocessor → Logistic Regression
Tree	Binario; hoja ≥ 5; no dividir < 10; profundidad ≤ 5; mayoría 95 %	Learner → Test and Score
Random Forest	100 árboles; semilla fija; no dividir subconjuntos < 5	Learner → Test and Score
Logistic Regression	Ridge (L2), C = 1	Learner → Test and Score
Test and Score	Validación cruzada de 10 pliegues, estratificada	Evaluation Results → Confusion Matrix, ROC Analysis
File (clustering)	5 variables; el resto como meta (incluye `nivel_co2_pc`)	Data → k-Means
k-Means	k = 2…8 y k = 4; Normalize columns; k-means++; 10 reinicios; 300 iteraciones	Data → Silhouette Plot, Box Plot, Scatter Plot, Data Table

Aprendizaje supervisado

Planteamiento

Pregunta de predicción: *¿Se puede predecir si un país es emisor Bajo, Medio o Alto de CO2 per cápita a partir de su perfil energético y de sus emisiones de gases distintos al CO2?* Las predictoras describen cuánta energía usa el país, qué tan limpia es su red eléctrica y cuánto emite de otros gases y su tamaño y su región.

Clasificación y no regresión: El CO2 per cápita es continuo, pero va de 0,05 a 38 t por persona: en una regresión unos pocos países dominarían el error y para el proyecto interesa ubicar a un país en un nivel de emisión, no estimar la décima exacta y los umbrales los definió el equipo: 2 t como referencia de emisión baja por persona y 6 t y claramente por encima del promedio mundial (cerca de 4,7 t).

Tabla 6

Distribución de la variable objetivo

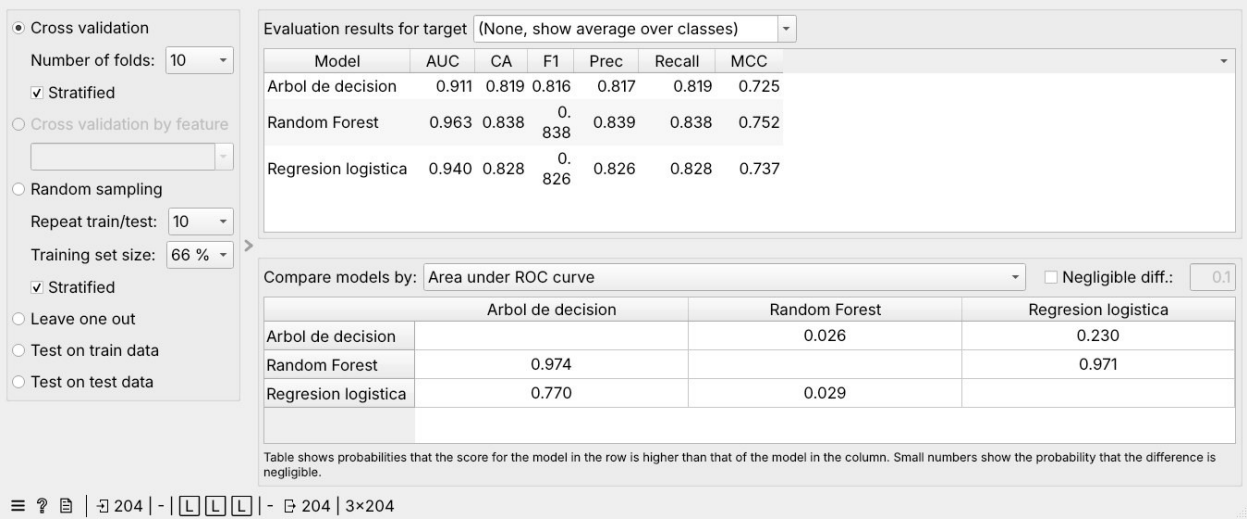
Clase	Países	%
Bajo	85	41,7
Medio	68	33,3
Alto	51	25,0
Total	204	100

Nota. El desbalance es moderado. Se usó validación estratificada, en la que cada pliegue conserva las proporciones, y se reportan métricas ponderadas y por clase. Un modelo que siempre dijera «Bajo» acertaría el 41,7 %: esa es la línea base que hay que superar.

Evaluación de los tres modelos

Figura 3

Resultados del widget Test and Score



Nota. Captura del flujo en Orange Data Mining. Validación cruzada de 10 pliegues estratificada; promedio sobre las clases.

Tabla 7

Métricas de los tres modelos (ponderadas)

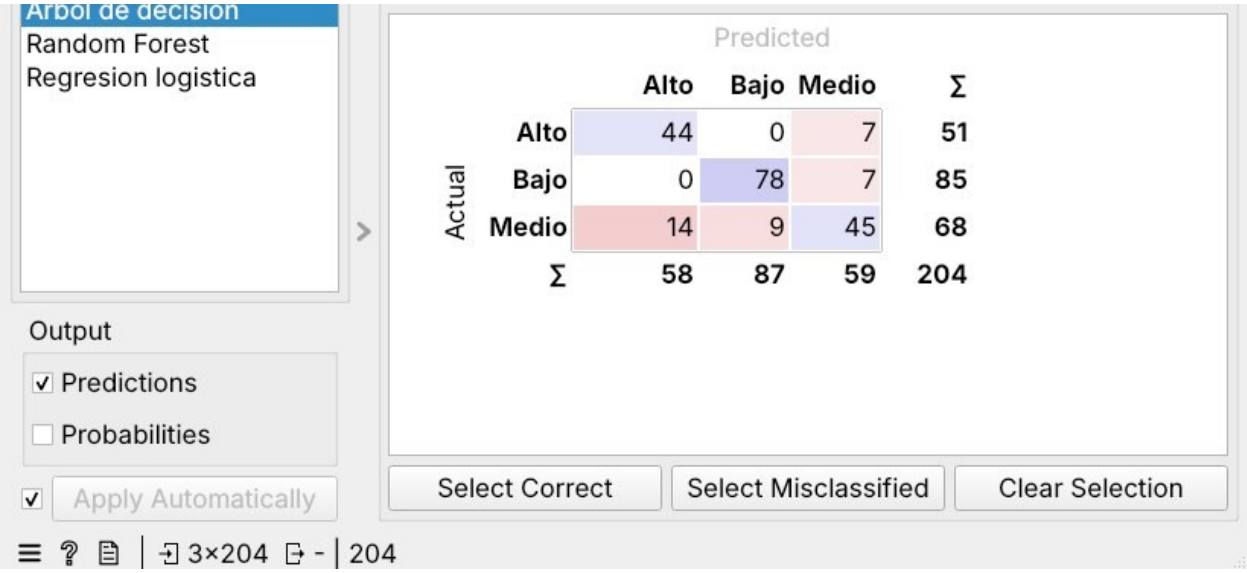
Modelo	**AUC**	**CA**	**F1**	**Precisión**	**Recall**	**MCC**
Árbol de decisión	0,911	0,819	0,816	0,817	0,819	0,725
Random Forest	0,963	0,838	0,838	0,839	0,838	0,752
Regresión logística	0,940	0,828	0,826	0,826	0,828	0,737

Los tres modelos superan ampliamente la línea base del 41,7 % y Random Forest es el mejor en todas las métricas y la comparación bayesiana de AUC de *Test and Score* indica que Random Forest supera al árbol con probabilidad 0,974 y a la regresión logística con 0,971 y el MCC, que va de −1 a 1, resume la matriz completa y es robusto al desbalance de clases.

Matrices de confusión y errores

Figura 4

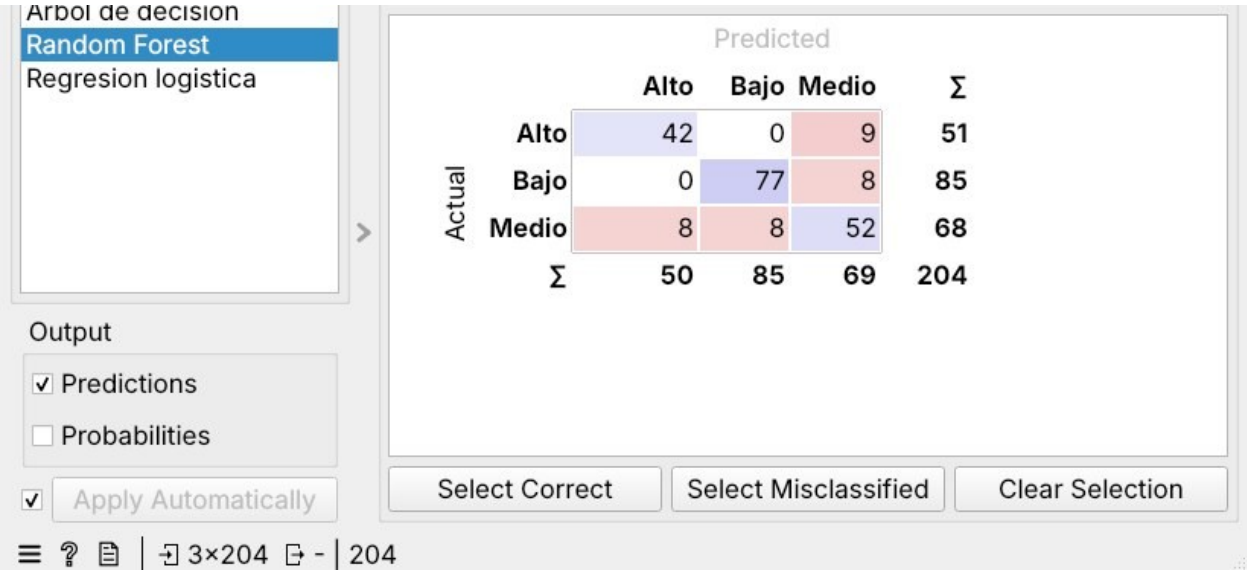
Matriz de confusión del árbol de decisión



Nota. Captura del flujo en Orange Data Mining.

Figura 5

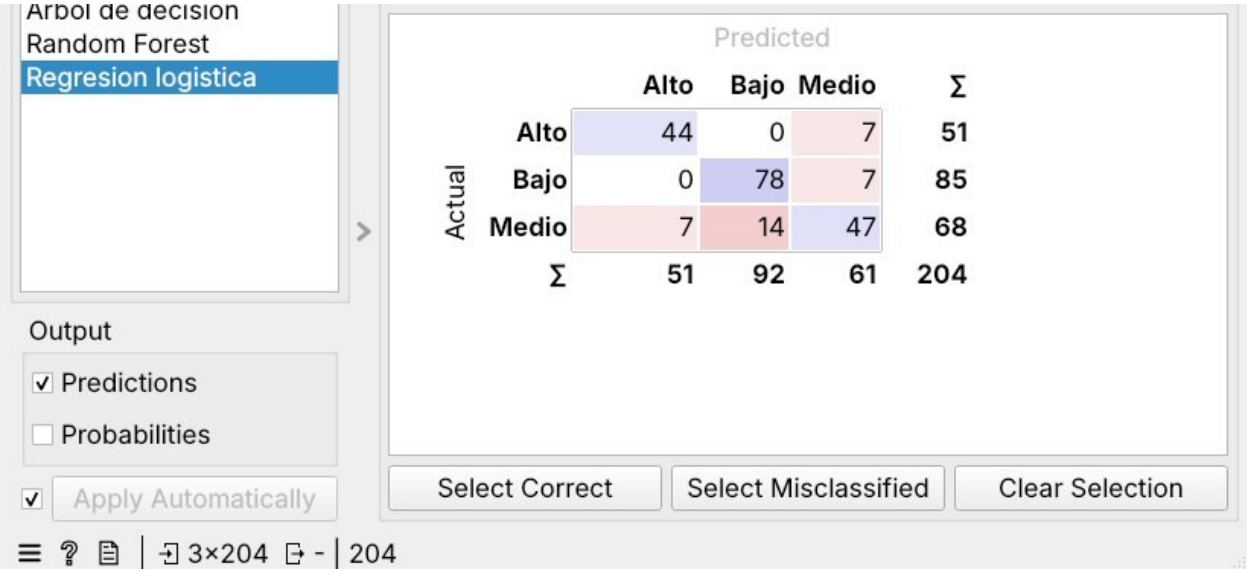
Matriz de confusión de Random Forest



Nota. Captura del flujo en Orange Data Mining.

Figura 6

Matriz de confusión de la regresión logística



Nota. Captura del flujo en Orange Data Mining.

Tabla 8

Precisión, recall y F1 por clase

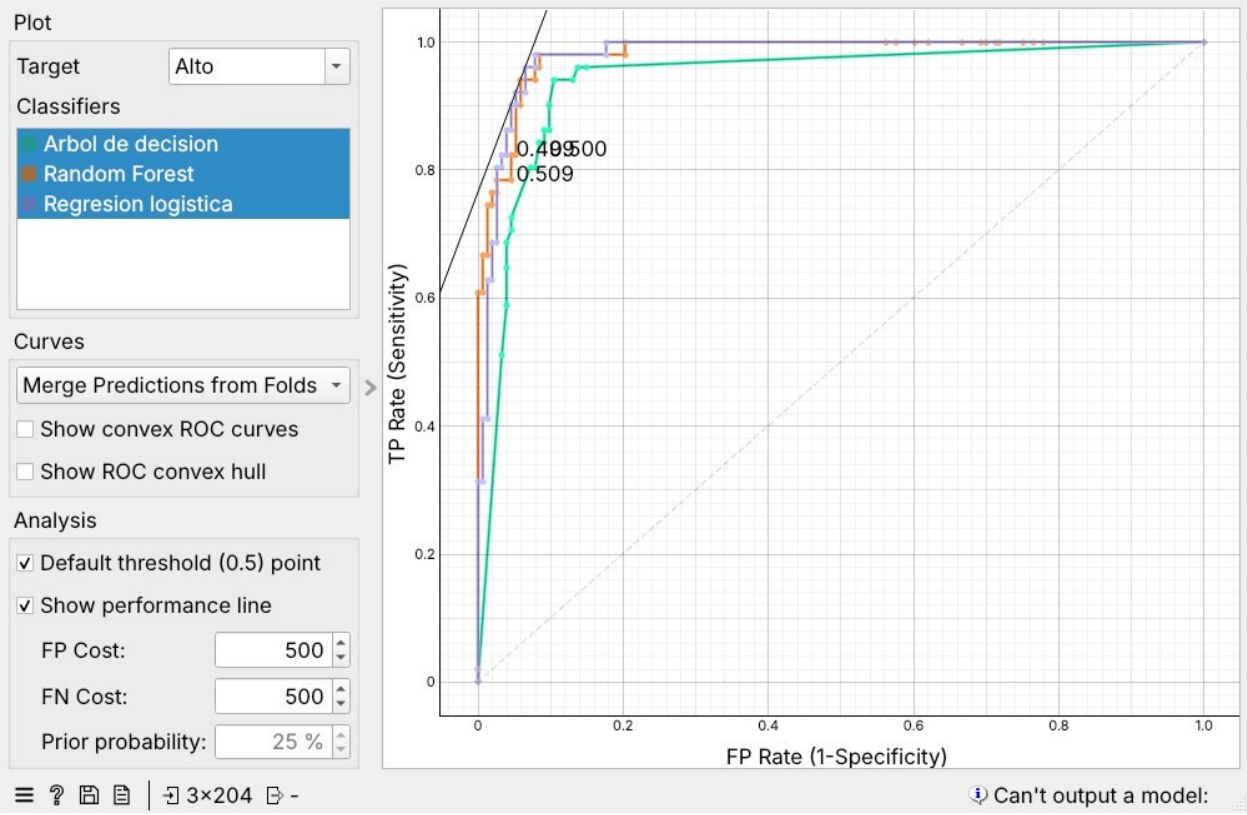
Clase	Árbol P	Árbol R	Árbol F1	RF P	RF R	RF F1	Log. P	Log. R	Log. F1
Bajo	0,90	0,92	0,91	0,91	0,91	0,91	0,85	0,92	0,88
Medio	0,76	0,66	0,71	0,75	0,77	0,76	0,77	0,69	0,73
Alto	0,76	0,86	0,81	0,84	0,82	0,83	0,86	0,86	0,86

Ningún modelo confunde Bajo con Alto: todos los errores involucran a la clase Medio, que es la frontera entre las otras dos y el árbol llama «Alto» a 14 países Medios y la regresión logística los llama «Bajo» (14) y random Forest reparte sus errores (8 y 8) y es el que más Medios acierta, 52 de 68.

Curva ROC e importancia de las variables

Figura 7

Curva ROC para la clase Alto

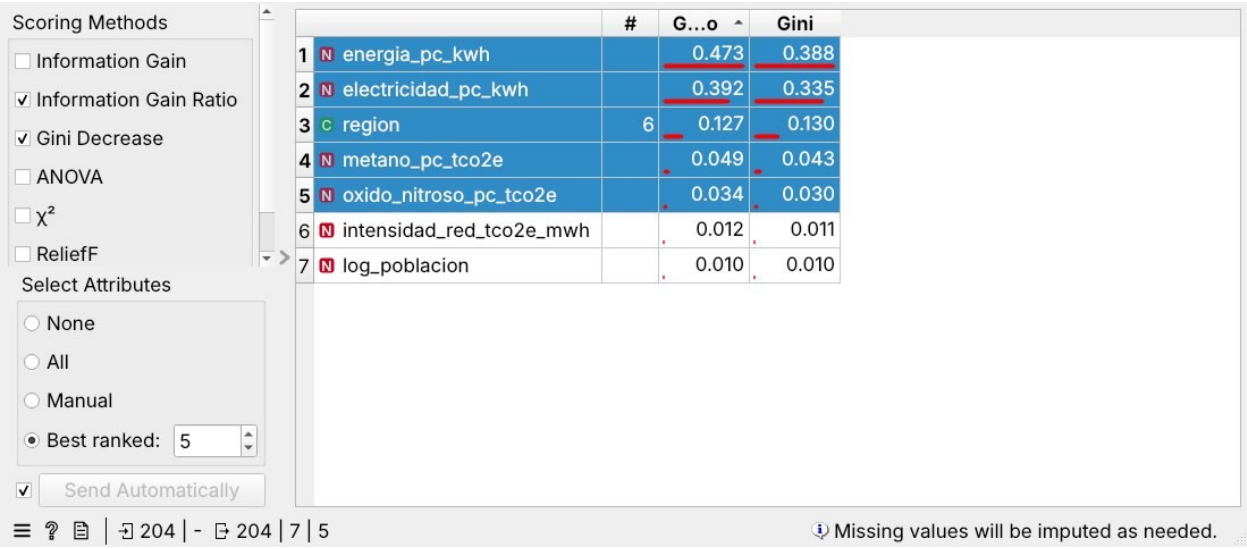


Nota. Captura del flujo en Orange Data Mining.

Las tres curvas quedan muy por encima de la diagonal, que representa un clasificador al azar.

Figura 8

Importancia de las predictoras (Rank)



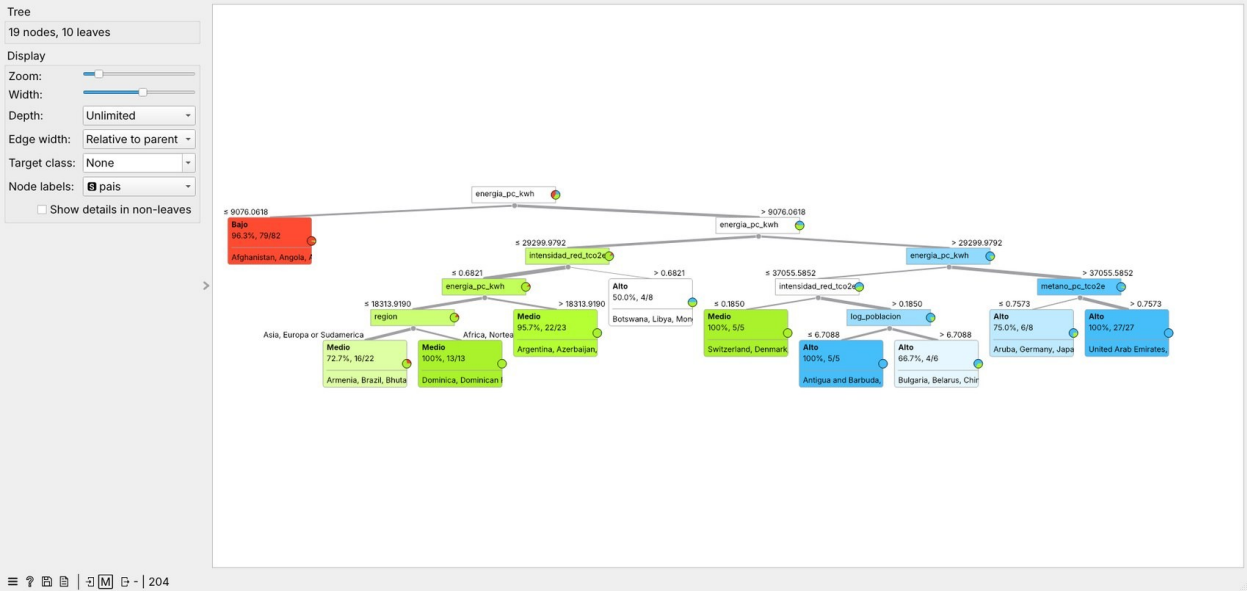
Nota. Captura del flujo en Orange Data Mining. Ganancia de información, razón de ganancia y Gini.

Energía y electricidad per cápita son, con diferencia, las variables más informativas (ganancia de información 0,946 y 0,784) y en Random Forest suman el 67 % de la importancia y la intensidad de la red casi no informa sola (0,024) y pero el árbol la usa después de la energía para separar Medio de Alto.

Reglas del árbol de decisión

Figura 9

Árbol de decisión entrenado con todos los datos (Tree Viewer)



Nota. Captura del flujo en Orange Data Mining. Se usa solo para interpretar; las métricas provienen de la validación cruzada.

- Energía ≤ 9.076 kWh por persona → Bajo (79 de 82 países, 96 %).
- Energía entre 9.076 y 29.300 kWh e intensidad de la red ≤ 0,68 t/MWh → Medio (51 de 58).
- Energía > 37.056 kWh y metano > 0,76 t por persona → Alto (27 de 27, 100 %).
- Energía entre 29.300 y 37.056 kWh con red muy limpia (≤ 0,185 t/MWh) → Medio (Suiza, Dinamarca y otros).

Caso Colombia: Colombia emite 1,8 t por persona (Bajo), consume 11.362 kWh por persona y su red emite 0,25 t/MWh y el árbol la ubica en Medio: está a 0,2 t del umbral y su red hidroeléctrica es lo que la mantiene abajo.

Modelo seleccionado: Random Forest

Se selecciona **Random Forest** porque es el mejor en todas las métricas (AUC 0,963 y F1 0,838 y MCC 0,752), la diferencia es creíble (97 % de probabilidad de superar a los otros dos en AUC), maneja mejor la clase difícil (Medio y F1 0,76) y no exige estandarizar y ni linealidad y tolera valores extremos.

Conocimiento que aporta: El nivel de emisión de un país se explica sobre todo por cuánta energía usa y, en segundo lugar, por cómo la produce (red eléctrica) y por el metano y esto va más allá de las etapas descriptivas y que mostraban el nivel pero no qué lo explica.

Limitaciones: Es menos interpretable que el árbol, por eso el árbol se mantiene como apoyo para explicar reglas y con 204 países cada pliegue evalúa unos 20, así que las métricas tienen una incertidumbre de algunos puntos y el modelo muestra asociación y no causalidad usa promedios 2020-2024 que incluyen el año atípico de la pandemia y los umbrales de clase son una decisión del equipo.

Clustering

Planteamiento y elección de k

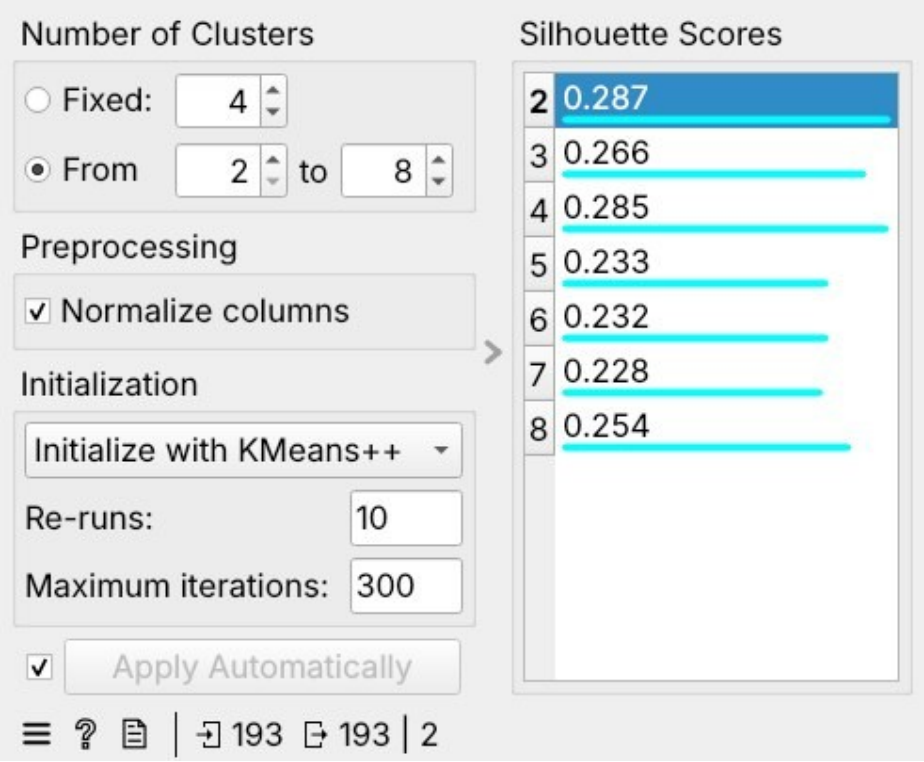
Pregunta: *¿Qué perfiles energético-emisores comparten los países, más allá de su nivel de CO2 per cápita?*.

Variables: Se usaron el log10 de energía, electricidad, metano y óxido nitroso per cápita y la intensidad de la red y no se usaron el CO2 el nivel de emisión (objetivo del supervisado y que queda como meta) ni la región y para ver si los perfiles cruzan continentes y las variables se estandarizaron porque k-Means usa distancias y sin estandarizar y la variable con mayor escala dominaría la agrupación.

Algoritmo: k-Means con inicialización k-means++, 10 reinicios y 300 iteraciones y se compararon k = 2 a 8 con la silueta, que va de −1 a 1 y es más alta cuando los grupos son compactos y están separados.

Figura 10

Silueta por número de grupos en k-Means



Nota. Captura del flujo en Orange Data Mining.

Tabla 9

Comparación de k

k	Silueta
2	0,287
3	0,266
4	0,285
5	0,233
6	0,232
7	0,228
8	0,254

Nota. Una silueta cercana a 0,3 indica estructura real pero con fronteras difusas entre grupos (Rousseeuw, 1987).

Elección: k = 4: k = 2 y k = 4 tienen casi la misma silueta (0,287 y 0,285) y con k = 2 solo se divide «mucha o poca energía» y con k = 4 se distinguen además la limpieza de la red y el metano, que es lo que interesa al proyecto.

Caracterización de los grupos

Tabla 10

Medianas por grupo (k = 4)

Grupo	n	Energía kWh/p	Electr. kWh/p	Red t/MWh	Metano t/p	N_2O t/p	Var. CO2 %/año	CO2 t/p	Silueta
C1	59	25.570	4.505	0,19	1,14	0,47	−1,6	4,5	0,25
C2	32	31.007	4.940	0,66	3,22	0,34	+1,1	8,0	0,02
C3	48	1.359	155	0,36	0,93	0,28	+2,9	0,3	0,37
C4	54	10.664	1.713	0,60	0,56	0,16	+1,0	2,5	0,19

Nota. El CO2 y su variación no se usaron para agrupar; se muestran para describir. La silueta por grupo sale del Silhouette Plot.

Tabla 11

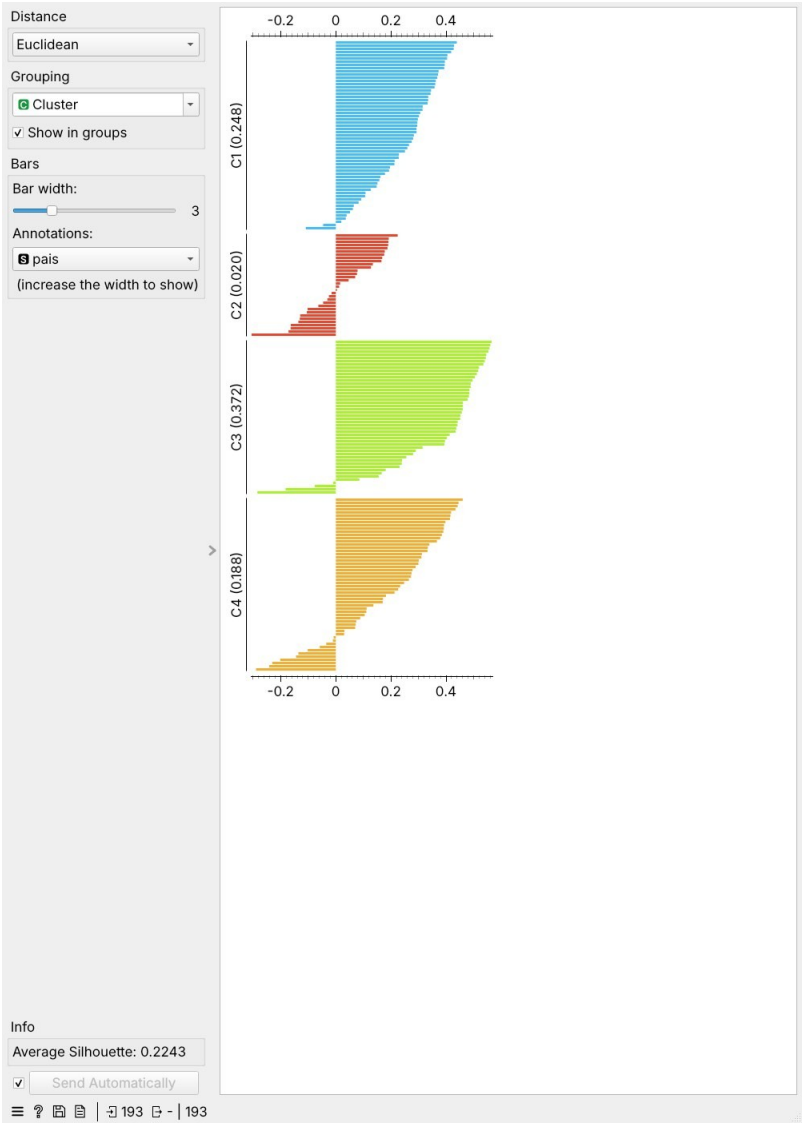
Nivel de CO2 per cápita dentro de cada grupo

Grupo	Bajo	Medio	Alto
C1	10	32	17
C2	2	8	22
C3	48	0	0
C4	22	25	7

Nota. C3 es 100 % Bajo y C2 concentra los Altos, pero C1 y C4 mezclan los tres niveles: el mismo nivel de emisión se alcanza con perfiles distintos.

Figura 11

Silhouette Plot con k = 4



Nota. Captura del flujo en Orange Data Mining.

C1 · Red eléctrica limpia y emisiones a la baja (59 países)

Consumo de energía alto o medio con la red eléctrica menos intensiva en carbono (hidroeléctrica o nuclear) y es el único grupo cuyas emisiones de CO2 bajan en el periodo.

Regiones: Europa 32, Sudamérica 10, Asia 8 y Norteamérica 6 y **ejemplos:** Eslovaquia y Francia y Hungría y Croacia y España (y Colombia).

Para decidir: Referente de desacople: se puede consumir energía sin emitir al ritmo de los fósiles y Colombia está aquí y el reto es proteger la generación hídrica frente a sequías como las de El Niño 2023-2024.

C2 · Productores de hidrocarburos intensivos en carbono (32 países)

El consumo de energía más alto, la red más sucia y el metano per cápita más alto (extracción de petróleo y gas) y concentra la mayoría de los emisores Altos.

Regiones: Asia 19, África 5, Europa 4 y Sudamérica 2 y **ejemplos:** Kazajistán y Libia y Brunéi y Arabia Saudita y Turkmenistán.

Para decidir: Prioridad para políticas de metano (fugas y quema en antorcha) y para descarbonizar la red.

C3 · Baja energía y baja electrificación (48 países)

Consumo de energía y electricidad muy bajos y todos son emisores Bajos y sin embargo, es el grupo cuyas emisiones crecen más rápido.

Regiones: África 36, Asia 7, Norteamérica 4 y Oceanía 1 y **ejemplos:** Tanzania y Uganda y Madagascar y Etiopía y Burkina Faso.

Para decidir: Oportunidad para crecer con renovables desde el inicio: su emisión es baja hoy, pero la tendencia es al alza.

C4 · Transición intermedia dependiente de fósiles (54 países)

Consumo de energía intermedio con red eléctrica intensiva en carbono (diésel, carbón o gas) y poco metano y óxido nitroso y incluye muchas islas pequeñas e India.

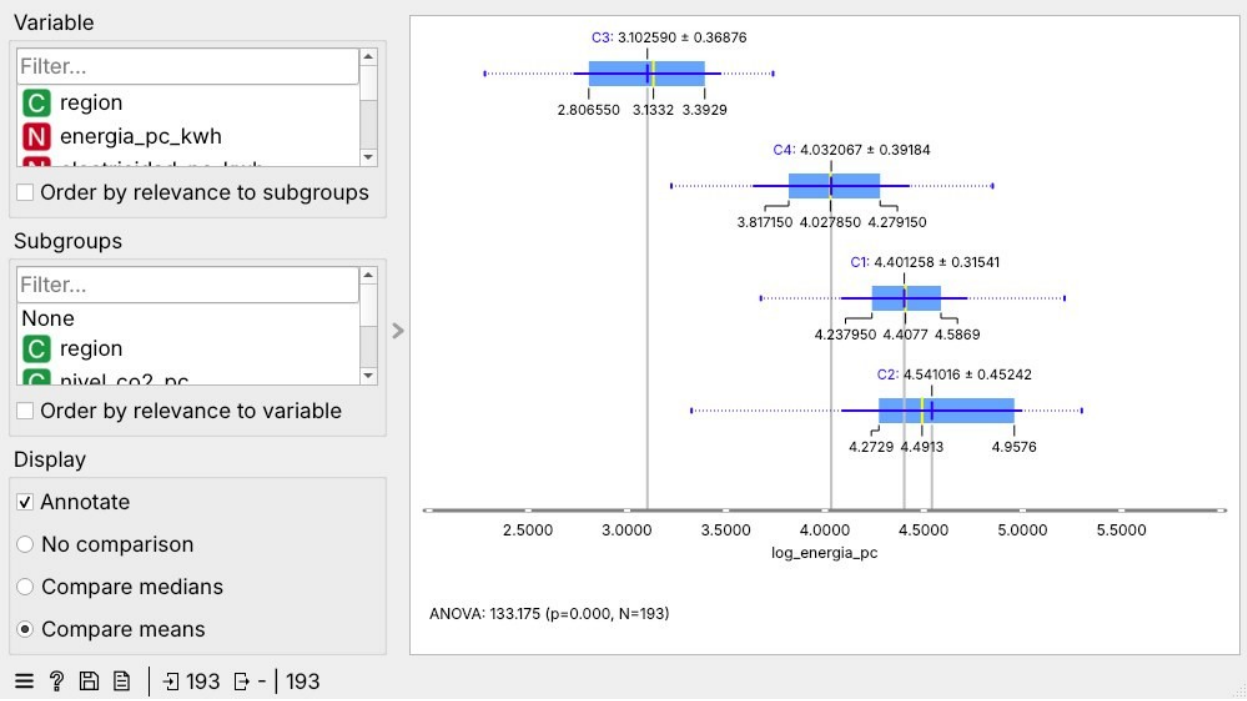
Regiones: Asia 16, Norteamérica 15, África 13 y Oceanía 7 y **ejemplos:** Santa Lucía y Granada y Maldivas y Mauricio y Jamaica.

Para decidir: La palanca es la red eléctrica: reemplazar generación fósil por renovable reduce emisiones sin frenar el consumo.

Evidencia visual de los grupos

Figura 12

Energía per cápita (log10) por grupo (Box Plot)

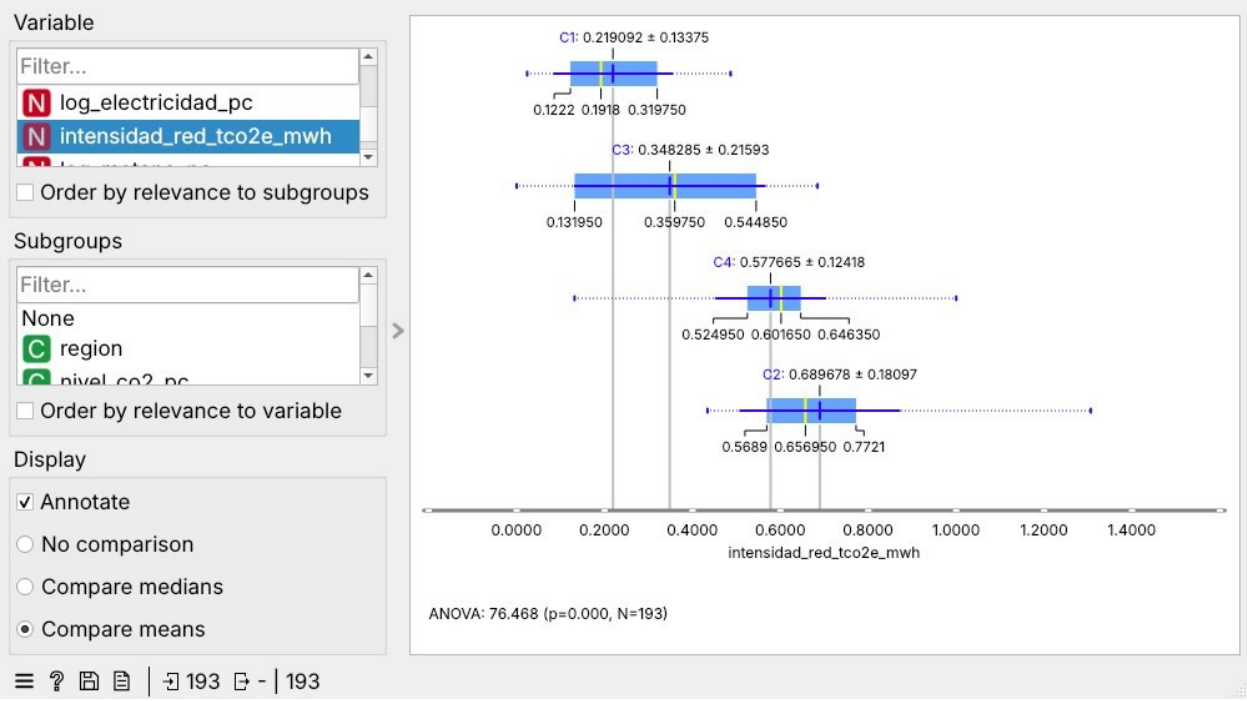


Nota. Captura del flujo en Orange Data Mining. ANOVA F = 133; p < 0,001.

C3 consume diez veces menos energía por persona que los demás grupos.

Figura 13

Intensidad de la red eléctrica por grupo (Box Plot)

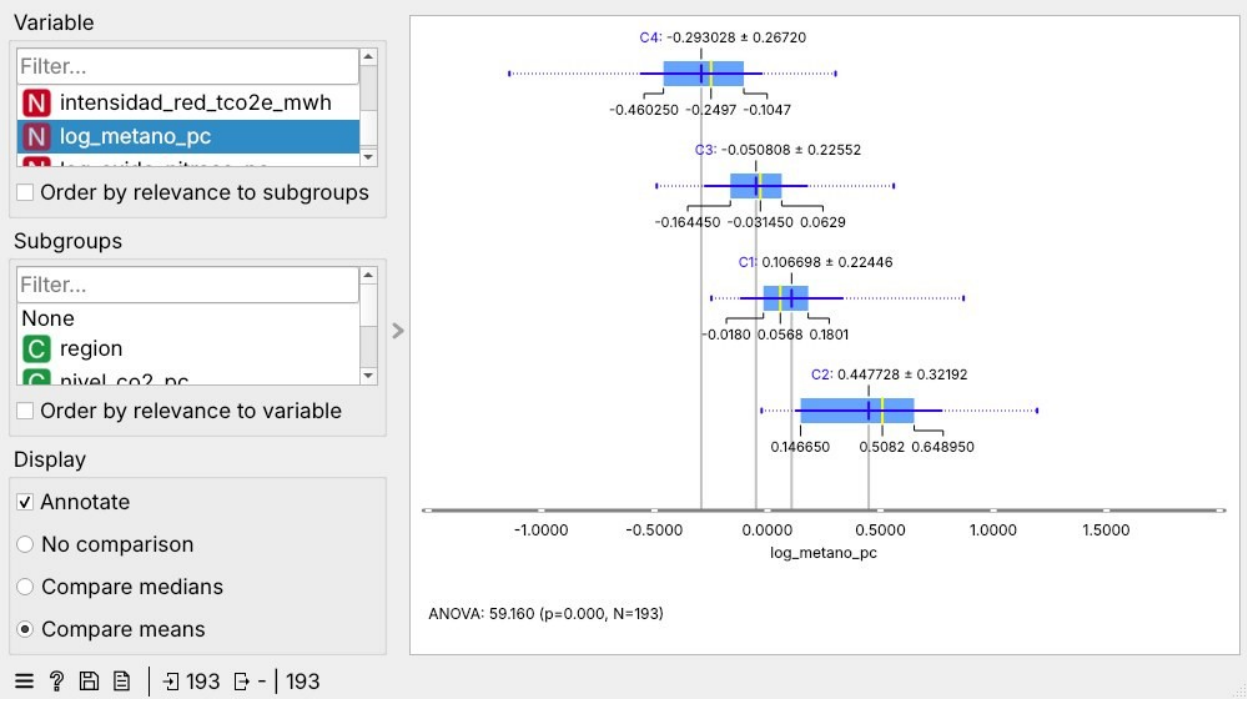


Nota. Captura del flujo en Orange Data Mining. ANOVA F = 76; p < 0,001.

C1 tiene la red más limpia y C2 y C4 las más intensivas en carbono.

Figura 14

Metano per cápita (log10) por grupo (Box Plot)

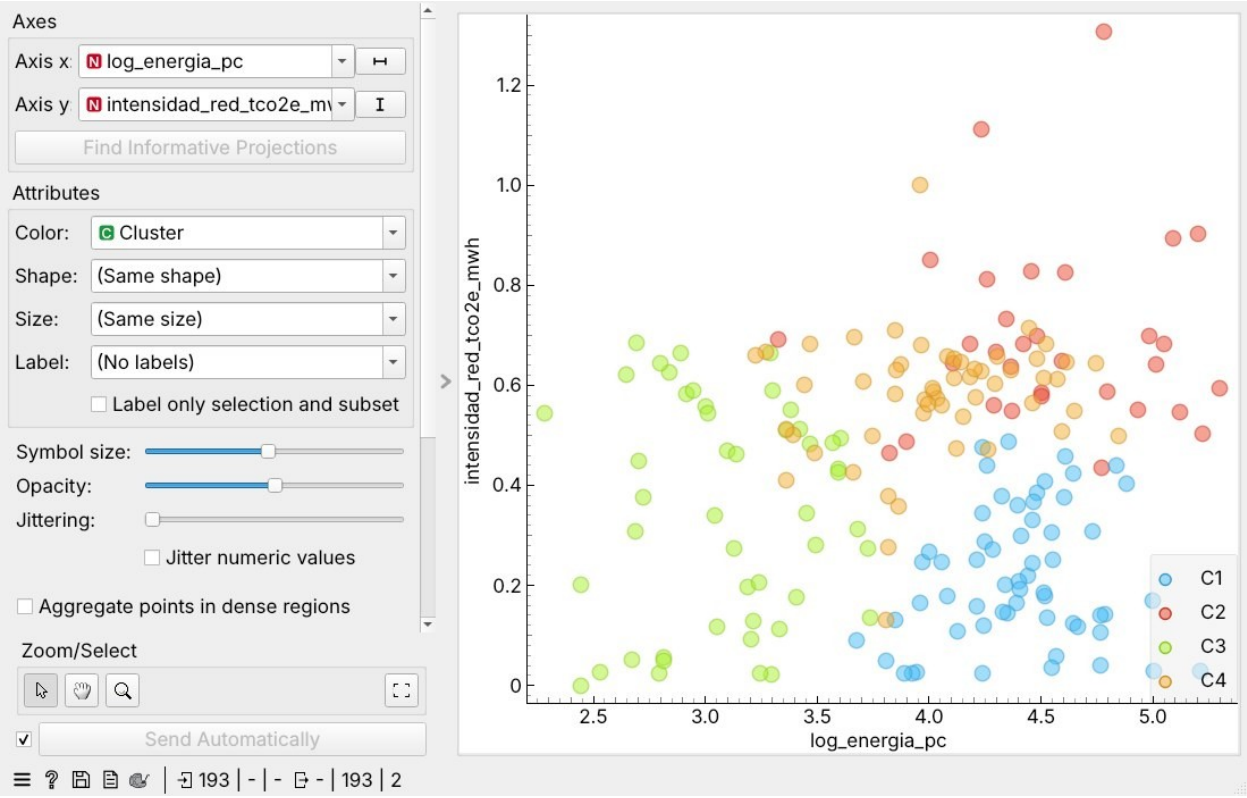


Nota. Captura del flujo en Orange Data Mining. ANOVA F = 59; p < 0,001.

C2 se separa del resto por su metano, ligado a la extracción de petróleo y gas.

Figura 15

Energía per cápita frente a intensidad de la red, coloreado por grupo (Scatter Plot)

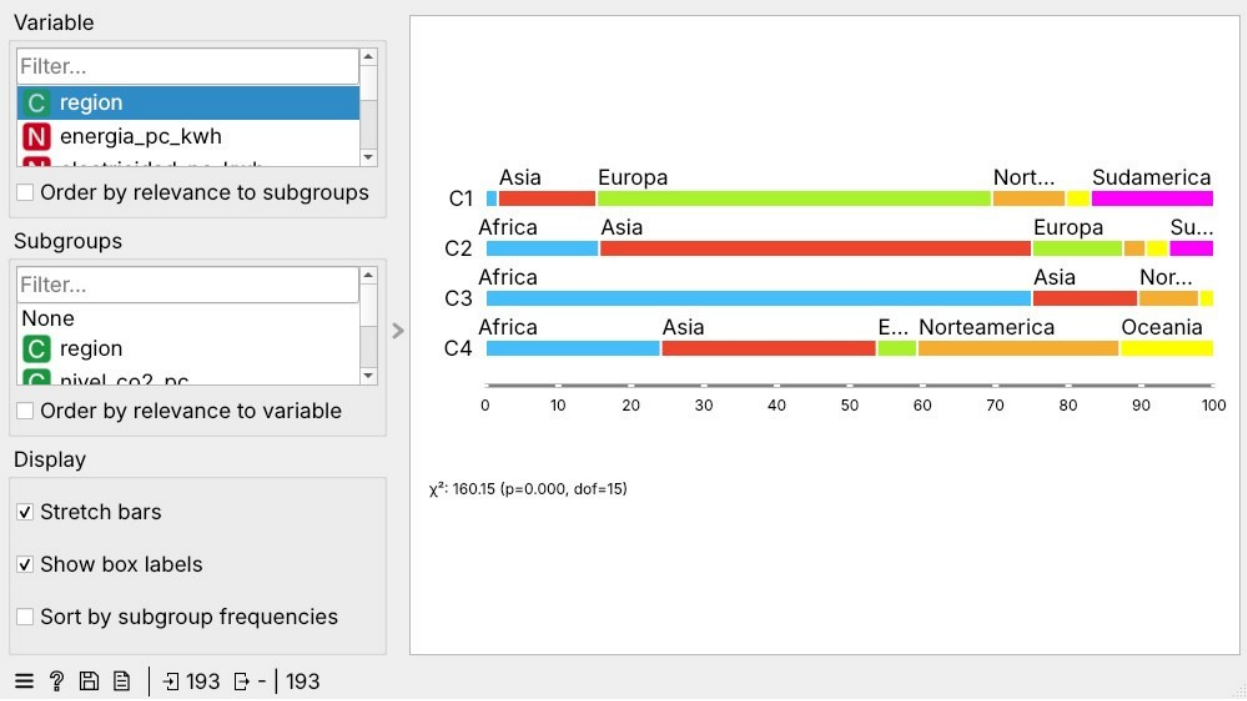


Nota. Captura del flujo en Orange Data Mining.

C1 (azul) y C4 (naranja) consumen una cantidad parecida de energía y lo que los separa es la limpieza de la red.

Figura 16

Región dentro de cada grupo (Box Plot con subgrupos)



Nota. Captura del flujo en Orange Data Mining. La región no se usó para agrupar.

Patrones ocultos que revela el clustering

1. **Igual nivel, trayectorias opuestas:** C1 y C4 tienen países Medios y Altos, pero C1 llega ahí con red limpia y emisiones que bajan (−1,6 % al año) y C4 con red sucia y emisiones que suben (+1,0 % al año).

2. **Sudamérica se parece a Europa:** 10 de 12 países sudamericanos, Colombia incluida, caen en C1 por su generación hidroeléctrica.

3. **Los que menos emiten crecen más rápido:** C3 es 100 % Bajo, pero su CO2 crece +2,9 % al año.

4. **El metano identifica a los productores de hidrocarburos** (C2) mejor que el consumo, y ese perfil cruza continentes.

Limitaciones: La silueta es moderada, el resultado es sensible a la elección de variables y a la transformación logarítmica, y 11 países quedaron fuera por datos faltantes.

Comentarios de YouTube

Propósito y criterios de selección

Propósito: Contrastar los hallazgos de los modelos (energía, red eléctrica, metano y diferencias entre países) con la percepción del público hispanohablante: si se reconoce el problema y si se asocia a la energía y si hay escepticismo y si aparecen Colombia o eventos externos como El Niño.

Criterios: Se buscó un video en español sobre cambio climático con un volumen suficiente de comentarios y se extrajeron los comentarios principales, sin respuestas, ordenados por fecha y con un máximo de 500.

Tabla 12

Video consultado y extracción

Dato	Valor
Video	Documental de DW en español sobre inundaciones, sequías y ciudades esponja
Canal	DW (Deutsche Welle)
Enlace	https://www.youtube.com/watch?v=0rzAluuejUw
Fecha de extracción	5 de noviembre de 2026
Comentarios extraídos	500 comentarios principales (máximo fijado: 500)
Periodo de los comentarios	agosto de 2022 a octubre de 2026
Campos guardados	texto, fecha y número de likes (sin datos de los autores)

Procedimiento de conexión a la API

1. Se creó un proyecto en Google Cloud Console, se habilitó YouTube Data API v3 y se generó una clave de API.

2. La clave se guarda como variable de entorno `YOUTUBE_API_KEY` (o como *Secret* de Google Colab) y nunca se escribe en el código ni en el repositorio.

3. El script `scripts/youtube_extraccion.py` llama al recurso `videos` para los metadatos y al recurso `commentThreads` para los comentarios, 100 por página, paginando con `nextPageToken`.

4. Solo se guardan el texto, la fecha, los likes y el número de respuestas de cada comentario y no se guardan el nombre el canal ni la foto de los autores.

```
cd climate-mining-app
$env:YOUTUBE_API_KEY = "<clave>"        # PowerShell; no se publica
python scripts/youtube_extraccion.py 0rzAluuejUw 500
python scripts/youtube_limpieza.py
```

Restricciones encontradas: La API tiene una cuota diaria de 10.000 unidades y devuelve como máximo 100 comentarios por página y solo se descargan comentarios públicos y los retenidos por moderación no aparecen, y las respuestas requieren otra llamada, por lo que no se incluyeron y los comentarios se extrajeron con un cuaderno de Google Colab equivalente al script del repositorio y ese cuaderno no guardaba el número de respuestas y por eso el script de limpieza lo completa con 0.

Preparación de los comentarios

El script `scripts/youtube_limpieza.py` aplica estas reglas: elimina vacíos y duplicados exactos (con el texto normalizado) y elimina comentarios sin palabras (solo emojis, enlaces o menciones) o con menos de 3 palabras y elimina spam con enlaces y palabras de promoción y quita URL y menciones y no corrige la ortografía y el idioma se detecta por palabras vacías y se conserva el español, que es el idioma de las stopwords y del análisis de sentimiento.

Tabla 13

Trazabilidad de la limpieza de comentarios

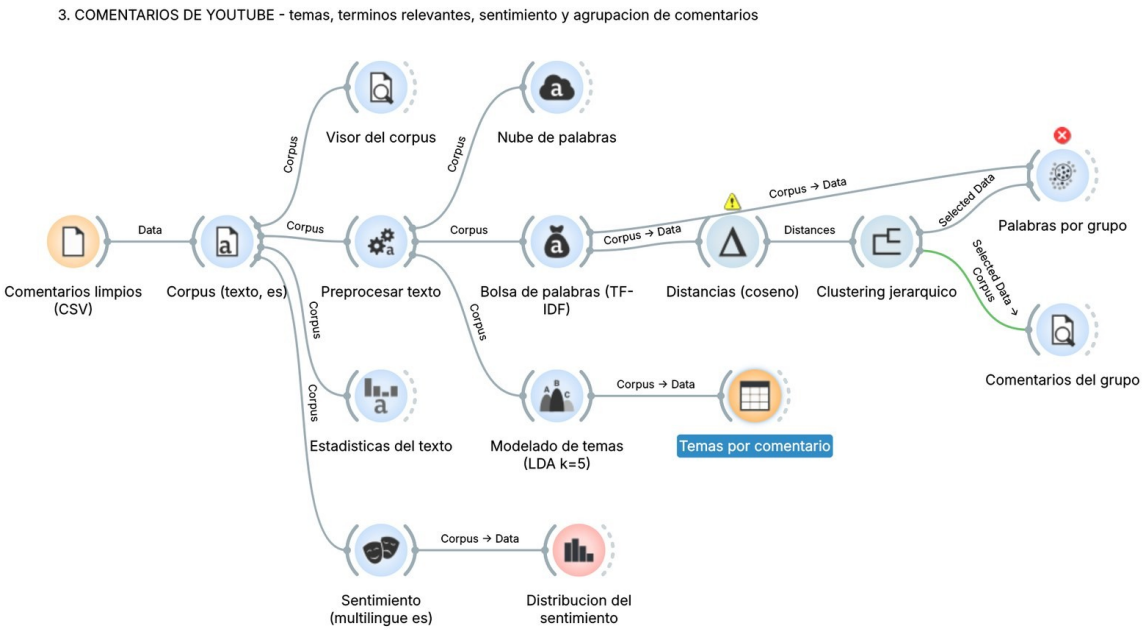
Paso	Comentarios
Comentarios extraídos	500
− Vacíos	0
− Duplicados exactos	3

Paso	Comentarios
− Sin texto (solo emojis, enlaces o menciones)	4
− Menos de 3 palabras	19
− Spam o promoción	0
− Otro idioma (3 en inglés) o indeterminado (8)	11
Corpus final (92,6 %)	463

Flujo de análisis de texto en Orange

Figura 17

Flujo etapa6_comentarios_youtube.ows



Nota. Captura del flujo en Orange Data Mining.

Tabla 14

Widgets y parámetros del flujo de texto

Widget	Parámetros
Corpus	Texto del comentario como variable de texto; idioma español
Preprocess Text	Minúsculas, sin URL; tokens por expresión regular; stopwords en español; elimina números, signos y tokens de 1-2 letras; frecuencia documental ≥ 3

Widget	Parámetros
Bag of Words	TF × IDF, normalización L2
Topic Modelling	LDA, 5 temas
Sentiment Analysis	Multilingual, español
Distances → Hierarchical Clustering	Distancia coseno; enlace promedio; Top N = 4; Word Enrichment por grupo

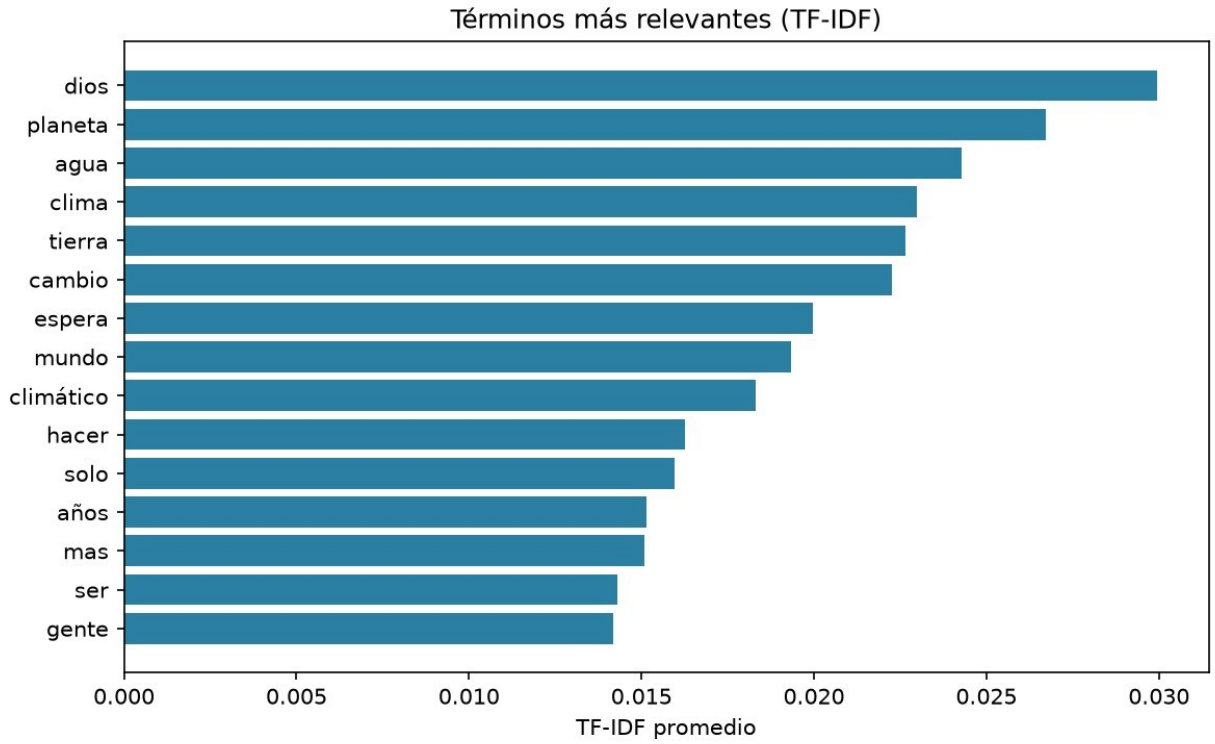
Hallazgos de los comentarios

Después del preprocesamiento el corpus quedó con 463 comentarios y un vocabulario de 581 términos que aparecen en al menos 3 comentarios y 9 comentarios quedaron sin términos y no entran al clustering.

Términos más relevantes

Figura 18

Términos con mayor peso TF-IDF promedio



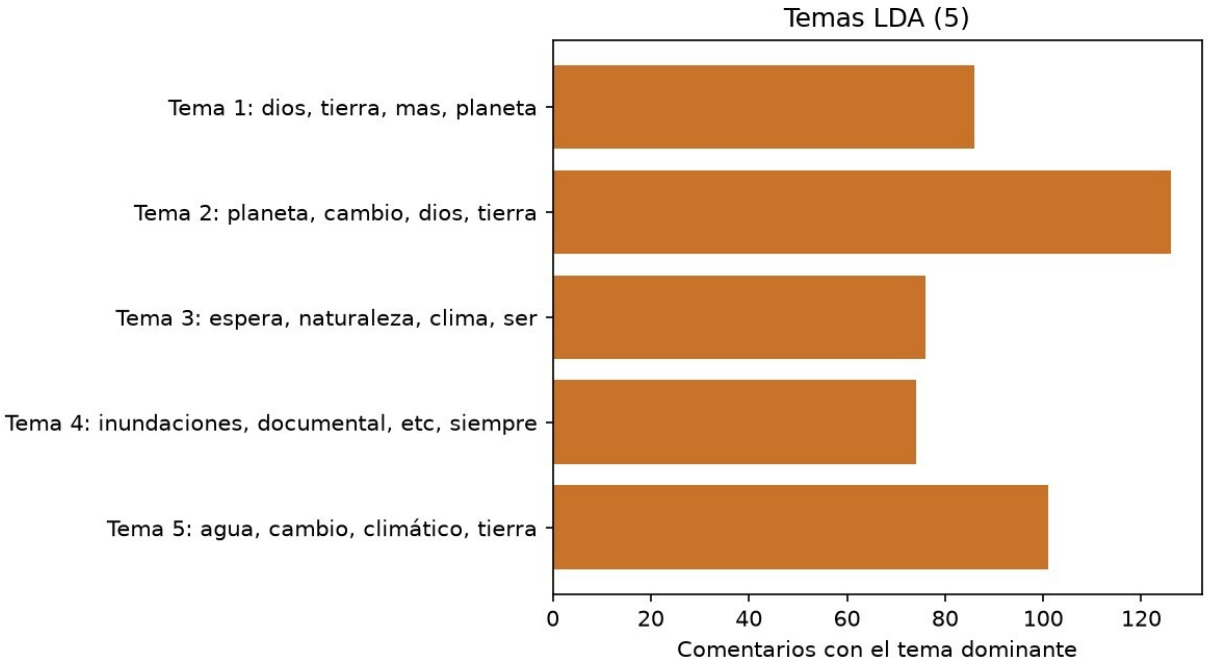
Nota. Elaboración propia con Orange Data Mining (orange3-text) sobre los comentarios limpios. Bag of Words con TF-IDF y normalización L2.

Los términos con más peso son **dios, planeta, agua y clima y tierra** y el vocabulario del público gira alrededor del planeta y del agua y de lo que «nos espera» y no alrededor de las causas que miden los datos: palabras como emisiones energía o carbono no aparecen entre los términos relevantes y la presencia de «dios» entre los primeros lugares muestra que una parte de los comentarios interpreta el problema en clave religiosa.

Temas (LDA)

Figura 19

Temas encontrados con LDA (5 temas)



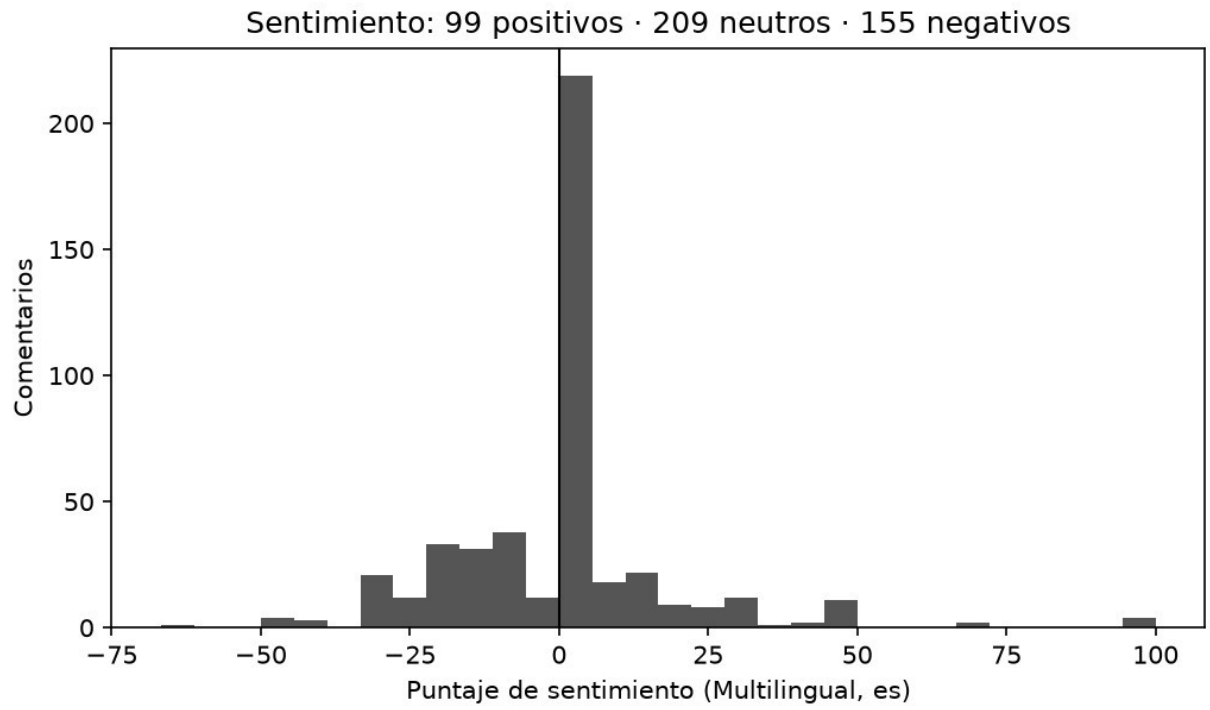
Nota. Elaboración propia con Orange Data Mining (orange3-text) sobre los comentarios limpios. Cada comentario se asigna a su tema dominante.

El modelo LDA encontró cinco temas que se solapan, algo esperable en comentarios cortos y se pueden leer así: un tema **religioso** (Tema 1: dios, tierra y mas y planeta y biblia y gente y 18,6 %) uno de **preocupación general por el planeta** (Tema 2: planeta y cambio y dios y tierra y mundo y solo y 27,2 %) uno **fatalista** sobre lo que viene (Tema 3: espera y naturaleza y clima y ser y hace y tan y 16,4 %) uno sobre **las inundaciones y el documental** (Tema 4: inundaciones y documental etc y siempre y clima y documentales y 16 %) y uno sobre **el agua y la lluvia y los países grandes** (Tema 5: agua y cambio y climático y tierra y países y grandes y 21,8 %).

Sentimiento

Figura 20

Distribución del sentimiento de los comentarios



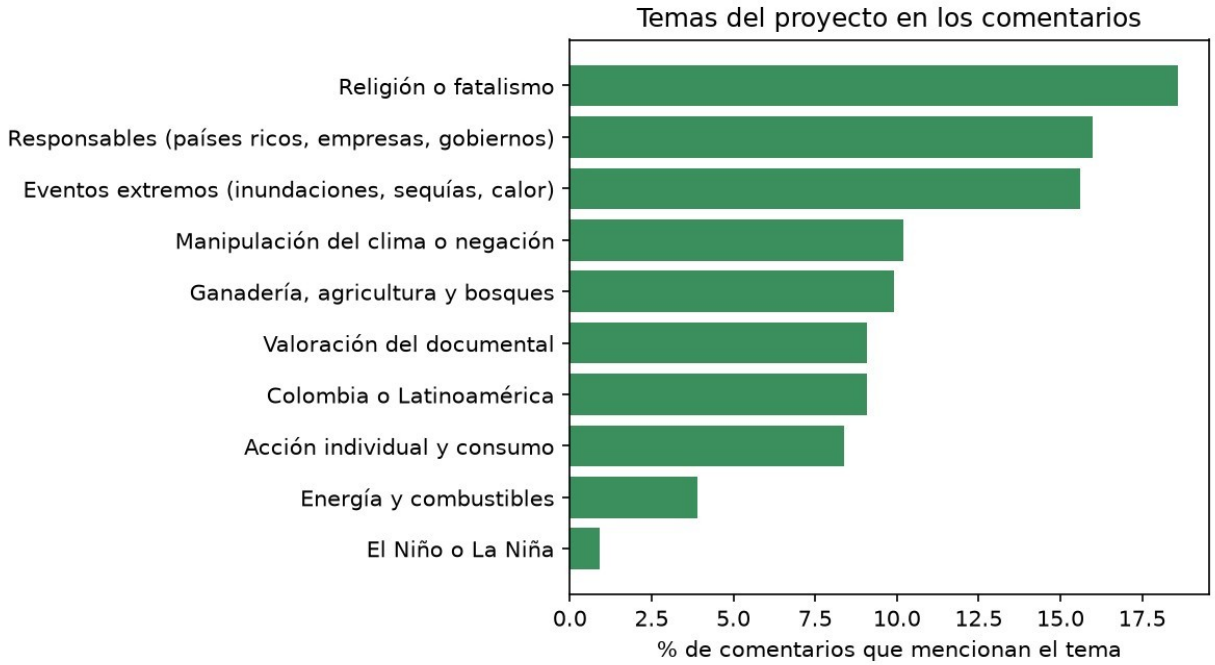
Nota. Elaboración propia con Orange Data Mining (orange3-text) sobre los comentarios limpios. Sentiment Analysis con el método Multilingual en español (léxico de Chen y Skiena, 2014).

De los 463 comentarios, **155 son negativos (33,5 %)**, 209 neutros y 99 positivos y la media es -0,58 y predomina un tono de preocupación y miedo o reproche y los positivos se concentran en la valoración del documental (sentimiento medio +14,47) y mientras que los comentarios sobre manipulación del clima o negación son los más negativos (media -9,05).

Temas del proyecto en los comentarios

Figura 21

Porcentaje de comentarios que mencionan cada tema del proyecto



Nota. Elaboración propia con Orange Data Mining (orange3-text) sobre los comentarios limpios. Búsqueda por raíz de palabra sobre el texto limpio.

Para contrastar los comentarios con los modelos se contó qué porcentaje menciona cada tema del proyecto y los temas más frecuentes son religión o fatalismo, los responsables (países ricos, empresas y gobiernos) y los eventos extremos y solo el 3,9 % menciona la energía o los combustibles y apenas el 0,9 % nombra El Niño o La Niña.

Tabla 15

Temas del proyecto en los comentarios

Tema	Comentarios	%	Sentimiento medio
Religión o fatalismo	86	18,6	-1,13
Responsables (países ricos, empresas, gobiernos)	74	16	-3,69
Eventos extremos (inundaciones, sequías, calor)	72	15,6	-2,34
Manipulación del clima o negación	47	10,2	-9,05

Tema	Comentarios	%	Sentimiento medio
Ganadería, agricultura y bosques	46	9,9	-3,47
Valoración del documental	42	9,1	14,47
Colombia o Latinoamérica	42	9,1	1,92
Acción individual y consumo	39	8,4	-4,62
Energía y combustibles	18	3,9	-3,83
El Niño o La Niña	4	0,9	7,14

Nota. Un comentario puede mencionar varios temas; el denominador son los 463 comentarios del corpus.

Grupos de comentarios (clustering jerárquico)

Con distancia coseno y enlace promedio, el clustering jerárquico no produjo grupos equilibrados: **436 comentarios quedan en un grupo general** (palabras características: planeta, agua y tierra y cambio y dios espera) y los otros tres grupos son pequeños y muy específicos: G2 (11: jajaja y mejor y saben y agricultura) y G4 (4: llama y señores y siglo y incas) y G3 (3: valencia y buscar obra y acabará) y entre ellos aparecen comentarios que culpan al «poder» o hablan de geoingeniería y otros que relacionan el video con la DANA de Valencia.

El resultado indica que los comentarios comparten casi todo el vocabulario y que las diferencias entre opiniones están en pocas palabras y por eso los temas LDA y el conteo por tema describen mejor el corpus que el clustering jerárquico, que sirve sobre todo para aislar comentarios atípicos.

Qué aportan los comentarios

Complementan: El público reconoce el problema y lo vive a través de los eventos extremos: inundaciones, sequías y calor aparecen en el 15,6 % de los comentarios, a veces con experiencias propias en Colombia y Argentina o España y eso coincide con la parte del proyecto que relaciona los indicadores con eventos externos.

Cuestionan: Los modelos dicen que el nivel de emisión depende sobre todo de la energía y de la red eléctrica, pero solo el 3,9 % de los comentarios habla de energía y el público atribuye

el problema a «los ricos», a los gobiernos o a la manipulación del clima (10,2 %) y una parte lo interpreta en clave religiosa (18,6 %).

Amplían: Aparecen temas que los datos numéricos no tienen, como la responsabilidad individual (8,4 %), la agricultura y los bosques (9,9 %) y soluciones de adaptación como la «ciudad esponja» del documental.

Alcance: Las opiniones corresponden a quienes comentaron el video seleccionado: no representan a la población de ningún país ni a toda la audiencia y sirven para generar hipótesis y contrastar percepciones, no para medir la opinión pública.

Conclusiones integradas

Nuevo conocimiento

1. **La energía explica el nivel y la red explica la diferencia:** El consumo de energía per cápita separa a los emisores Bajos (96 % en la primera regla del árbol) y entre países con un consumo parecido, la red eléctrica decide si son Medios o Altos y el modelo supervisado y el clustering coinciden en esto por caminos distintos.

2. **Colombia emite poco por su red, no por consumir poco:** Consume más que el umbral de los países Bajos, pero su red hidroeléctrica (0,25 t/MWh) la mantiene en 1,8 t por persona y el clustering la ubica con Europa y el resto de Sudamérica.

3. **Igual nivel, trayectorias opuestas:** Los países Medios de C1 reducen emisiones y los de C4 las aumentan: el nivel actual no dice hacia dónde va un país, el perfil sí.

4. **El crecimiento está en los que menos emiten:** El grupo de baja energía (C3) es 100 % Bajo pero crece +2,9 % al año y su trayectoria futura depende de cómo se electrifiquen esos países.

5. **El público ve los efectos pero no las causas:** En los comentarios dominan los eventos extremos, los responsables y la religión y la energía, que los modelos señalan como el factor principal y aparece en menos del 4 % y hay una brecha entre lo que explica las emisiones y lo que la gente asocia al cambio climático.

Coincidencias y diferencias entre los análisis

Tabla 16

Contraste entre modelos, clustering y comentarios

Tema	Supervisado	Clustering	Comentarios
Factor principal	Energía per cápita (67 % de la importancia en Random Forest)	La energía separa al grupo C3; la red y el metano separan C1, C2 y C4	Solo el 3,9 % habla de energía o combustibles
Responsables	Alto consumo de energía y metano	Productores de hidrocarburos (C2)	El 16 % culpa a países ricos, empresas o gobiernos

Tema	Supervisado	Clustering	Comentarios
Colombia	Frontera entre Bajo y Medio	Grupo de red limpia (C1)	El 9,1 % menciona Colombia o Latinoamérica, sobre todo por lluvias e inundaciones
Eventos externos	No se modelaron directamente	No se usaron para agrupar	El 15,6 % habla de eventos extremos; solo 4 comentarios nombran El Niño
Tono	No aplica	No aplica	33,5 % negativos; el escepticismo es el tema más negativo

Evidencia, hipótesis y decisiones

Tabla 17

Hallazgos respaldados por evidencia y hipótesis por validar

Respaldado por evidencia	Hipótesis por validar
Energía y electricidad per cápita son las variables más asociadas al nivel de CO2 (Rank, Random Forest y árbol).	Que mejorar la red reduzca el CO2: el modelo muestra asociación, no causa.
El modelo clasifica bien el 84 % de los países en validación cruzada.	Que el crecimiento de C3 continúe: solo hay 5 años y uno es de pandemia.
Los cuatro perfiles difieren de forma significativa (ANOVA $p < 0{,}001$).	Que la percepción del público coincida con los datos: los comentarios no son representativos.
10 de 12 países sudamericanos comparten el perfil de red limpia.	La relación con eventos externos (El Niño, COP) no se modeló directamente.
Solo el 3,9 % de los comentarios menciona la energía, frente al 15,6 % que habla de eventos extremos.	Que esta brecha exista en el público en general: es un solo video y los comentaristas no son una muestra representativa.

- **Comparar a Colombia con países de su perfil** (C1) y no solo con sus vecinos.
- **Proteger y diversificar la generación renovable**, porque es lo que mantiene a Colombia en nivel Bajo, y El Niño 2023-2024 mostró su vulnerabilidad.
- **Seguir el metano** en los países productores de hidrocarburos (C2).
- **Vigilar la tendencia y no solo el nivel** de emisión de cada país.

- **Comunicar las causas y no solo los efectos:** las campañas sobre cambio climático deberían conectar las inundaciones y sequías que la gente ya ve con el consumo de energía y la red eléctrica, que es lo que los modelos señalan.
- **Responder a la desinformación:** un 10,2 % de los comentarios habla de manipulación del clima o niega el problema y es un público al que hay que llegar con evidencia.

Limitaciones y reproducibilidad

Limitaciones

- Pocos casos (204 y 193 países) frente a la variedad que hay entre ellos.
- Promedios 2020-2024 que incluyen el año atípico de la pandemia.
- Umbrales de clase definidos por el equipo.
- Silueta moderada en el clustering.
- Un solo proveedor terciario para los indicadores (Our World in Data).
- Comentarios de un único video, en español, escritos por quienes decidieron comentar.

Cómo reproducir el trabajo

```
cd climate-mining-app
python scripts/conocimiento_oculto.py          # genera los CSV de data/etapa6/
# Orange 3.36 o superior: abrir data/etapa6/etapa6_conocimiento_oculto.ows
$env:YOUTUBE_API_KEY = "<clave>"
python scripts/youtube_extraccion.py 0rzAluuejUw 500
python scripts/youtube_limpieza.py             # comentarios_youtube_limpio.csv
# Orange + complemento Text: abrir data/etapa6/etapa6_comentarios_youtube.ows
python app.py                                  # sección Conocimiento Oculto
```

La sección **Conocimiento Oculto** de la aplicación Flask lee los resultados guardados en `data/etapa6/*.json`, presenta una síntesis de los hallazgos, permite descargar este informe y da acceso al video de sustentación.

Referencias

Arthur, D., & Vassilvitskii, S. (2007). k-means++: The advantages of careful seeding. En *Proceedings of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms* (pp. 1027–1035). SIAM.

Benavoli, A., Corani, G., Demšar, J., & Zaffalon, M. (2017). Time for a change: A tutorial for comparing multiple classifiers through Bayesian analysis. *Journal of Machine Learning Research, 18*(77), 1–36.

Blei, D. M., Ng, A. Y., & Jordan, M. I. (2003). Latent Dirichlet allocation. *Journal of Machine Learning Research, 3*, 993–1022.

Breiman, L. (2001). Random forests. *Machine Learning, 45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Chicco, D., & Jurman, G. (2020). The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation. *BMC Genomics, 21*, Artículo 6. https://doi.org/10.1186/s12864-019-6413-7

Demšar, J., Curk, T., Erjavec, A., Gorup, Č., Hočevar, T., Milutinovič, M., Možina, M., Polajnar, M., Toplak, M., Starič, A., Štajdohar, M., Umek, L., Žagar, L., Žbontar, J., Žitnik, M., & Zupan, B. (2013). Orange: Data mining toolbox in Python. *Journal of Machine Learning Research, 14*, 2349–2353.

Google. (s.f.). *YouTube Data API: CommentThreads*. Google for Developers. https://developers.google.com/youtube/v3/docs/commentThreads

Han, J., Kamber, M., & Pei, J. (2012). *Data mining: Concepts and techniques* (3.ª ed.). Morgan Kaufmann.

Ritchie, H., Rosado, P., & Roser, M. (2023). *CO_2 and greenhouse gas emissions*. Our World in Data. https://ourworldindata.org/co2-and-greenhouse-gas-emissions

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics, 20*, 53–65. https://doi.org/10.1016/0377-0427(87)90125-7

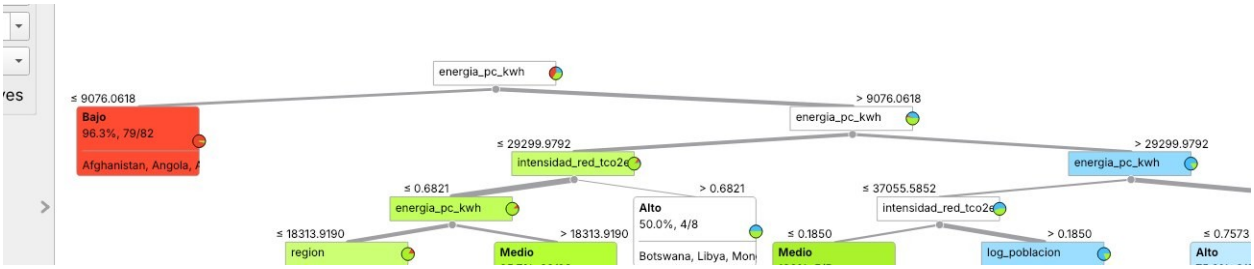
Apéndice A

Capturas complementarias de Orange

Este apéndice reúne capturas que complementan el desarrollo: el detalle del árbol, la tabla con la asignación de grupos, el k-Means con k = 4 y los diagramas de caja de las variables que no se mostraron en el cuerpo del informe.

Figura A1

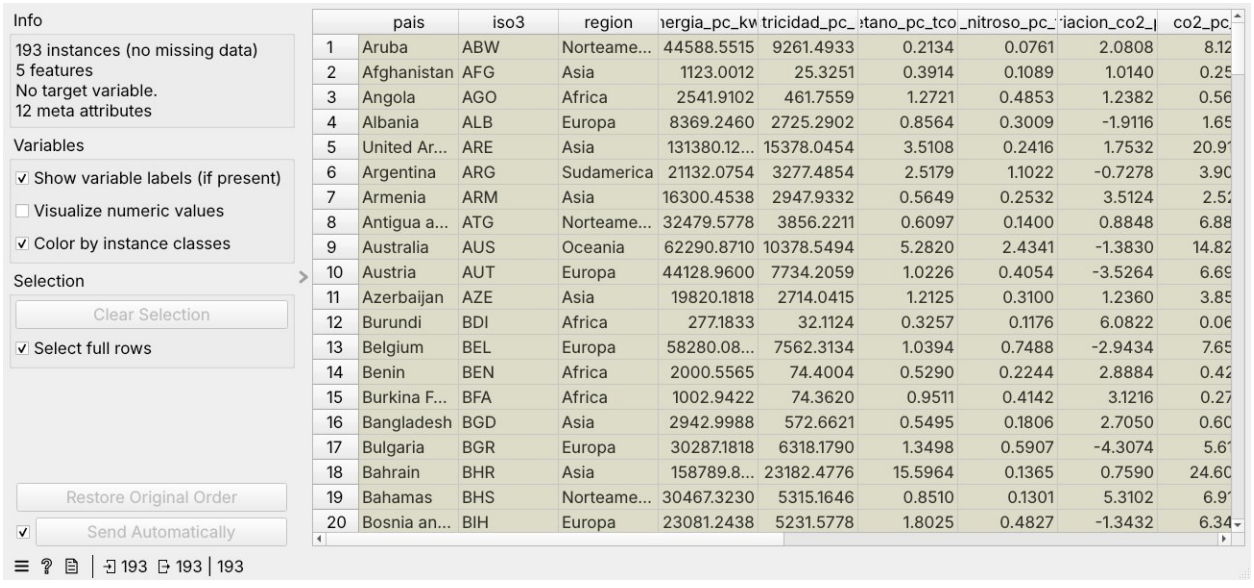
Detalle de la raíz del árbol de decisión



Nota. Captura del flujo en Orange Data Mining.

Figura A2

Tabla de países con su grupo asignado (Data Table)

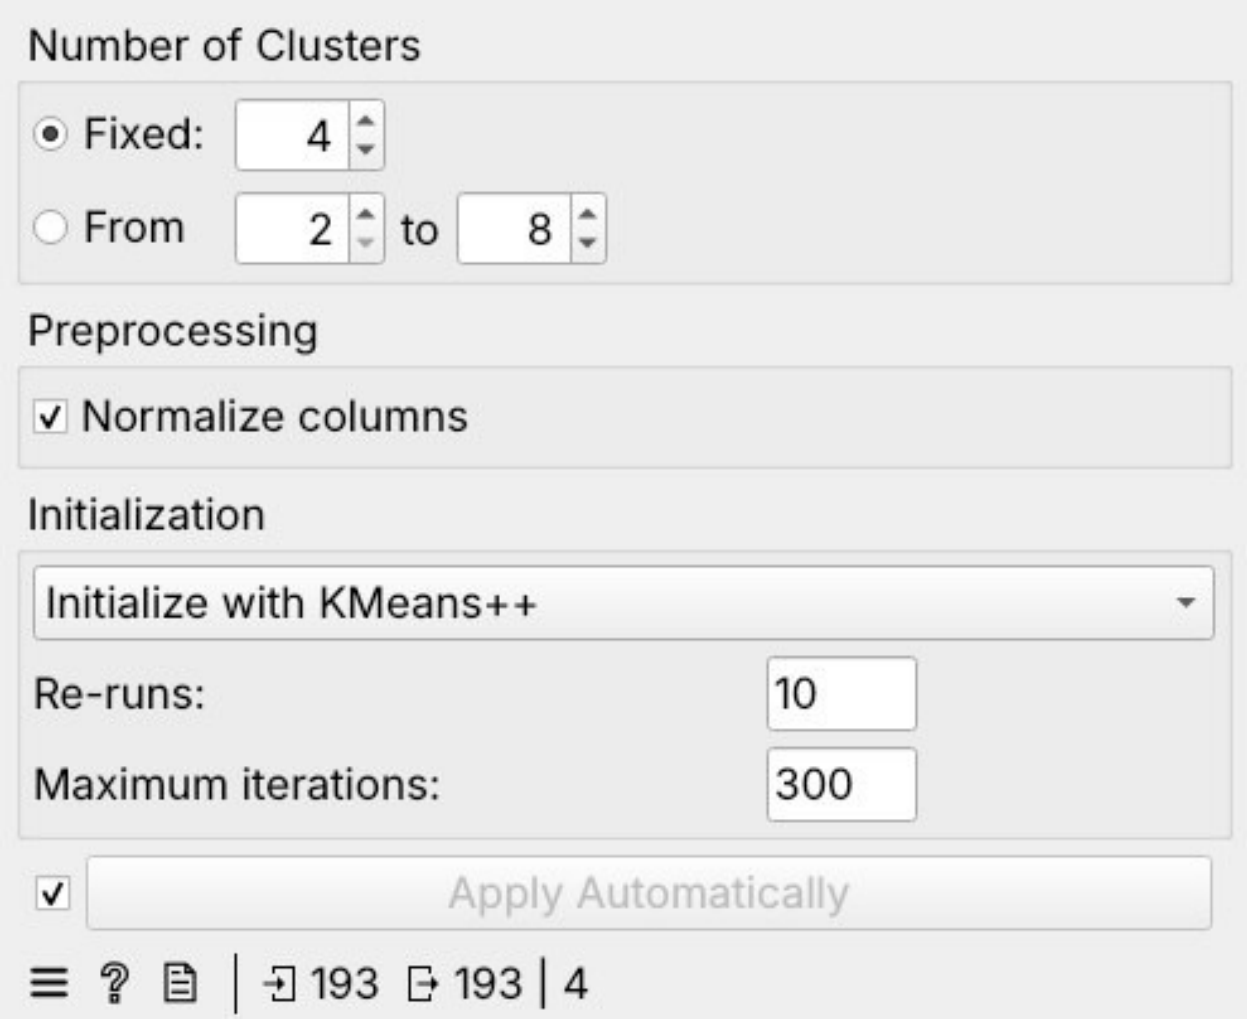


	pais	iso3	region	ıergia_pc_kw	tricidad_pc_	ːtano_pc_tco	_nitroso_pc_	ˈiacion_co2_	co2_pc
1	Aruba	ABW	Norteame...	44588.5515	9261.4933	0.2134	0.0761	2.0808	8.12
2	Afghanistan	AFG	Asia	1123.0012	25.3251	0.3914	0.1089	1.0140	0.25
3	Angola	AGO	Africa	2541.9102	461.7559	1.2721	0.4853	1.2382	0.56
4	Albania	ALB	Europa	8369.2460	2725.2902	0.8564	0.3009	-1.9116	1.65
5	United Ar...	ARE	Asia	131380.12...	15378.0454	3.5108	0.2416	1.7532	20.91
6	Argentina	ARG	Sudamerica	21132.0754	3277.4854	2.5179	1.1022	-0.7278	3.90
7	Armenia	ARM	Asia	16300.4538	2947.9332	0.5649	0.2532	3.5124	2.52
8	Antigua a...	ATG	Norteame...	32479.5778	3856.2211	0.6097	0.1400	0.8848	6.88
9	Australia	AUS	Oceania	62290.8710	10378.5494	5.2820	2.4341	-1.3830	14.82
10	Austria	AUT	Europa	44128.9600	7734.2059	1.0226	0.4054	-3.5264	6.69
11	Azerbaijan	AZE	Asia	19820.1818	2714.0415	1.2125	0.3100	1.2360	3.85
12	Burundi	BDI	Africa	277.1833	32.1124	0.3257	0.1176	6.0822	0.06
13	Belgium	BEL	Europa	58280.08...	7562.3134	1.0394	0.7488	-2.9434	7.65
14	Benin	BEN	Africa	2000.5565	74.4004	0.5290	0.2244	2.8884	0.42
15	Burkina F...	BFA	Africa	1002.9422	74.3620	0.9511	0.4142	3.1216	0.27
16	Bangladesh	BGD	Asia	2942.9988	572.6621	0.5495	0.1806	2.7050	0.60
17	Bulgaria	BGR	Europa	30287.1818	6318.1790	1.3498	0.5907	-4.3074	5.61
18	Bahrain	BHR	Asia	158789.8...	23182.4776	15.5964	0.1365	0.7590	24.60
19	Bahamas	BHS	Norteame...	30467.3230	5315.1646	0.8510	0.1301	5.3102	6.91
20	Bosnia an...	BIH	Europa	23081.2438	5231.5778	1.8025	0.4827	-1.3432	6.34

Nota. Captura del flujo en Orange Data Mining.

Figura A3

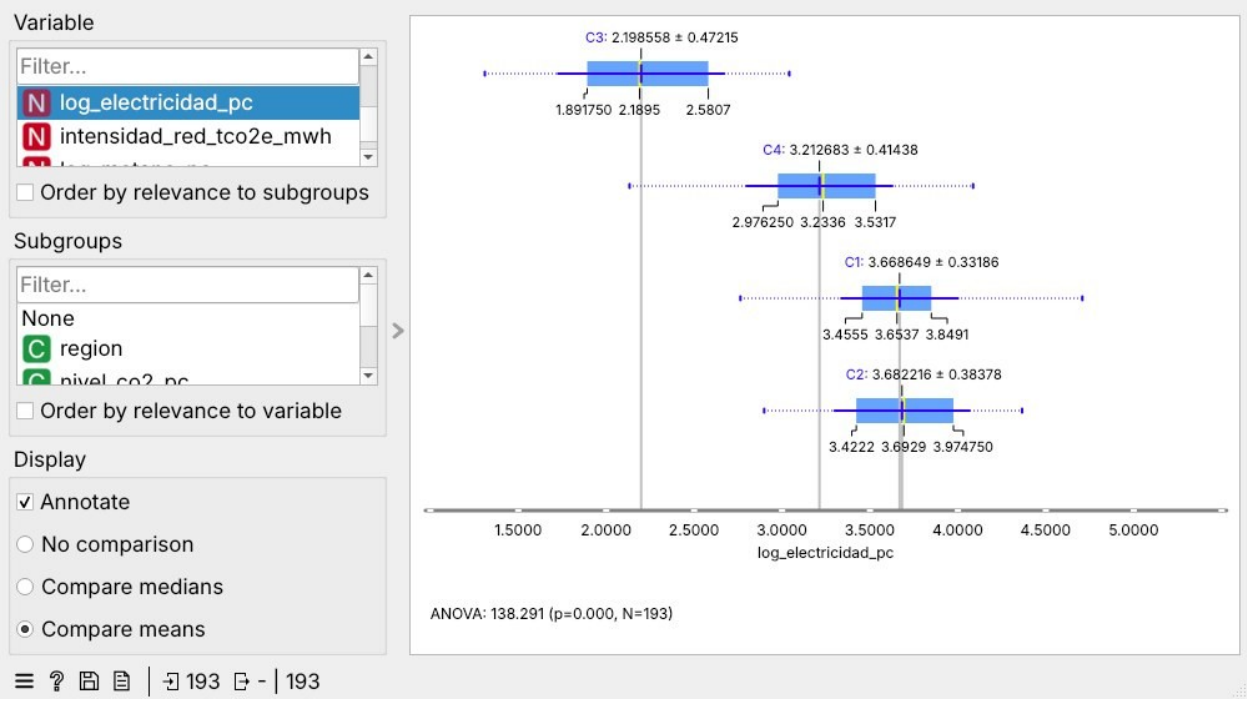
k-Means con k = 4



Nota. Captura del flujo en Orange Data Mining.

Figura A4

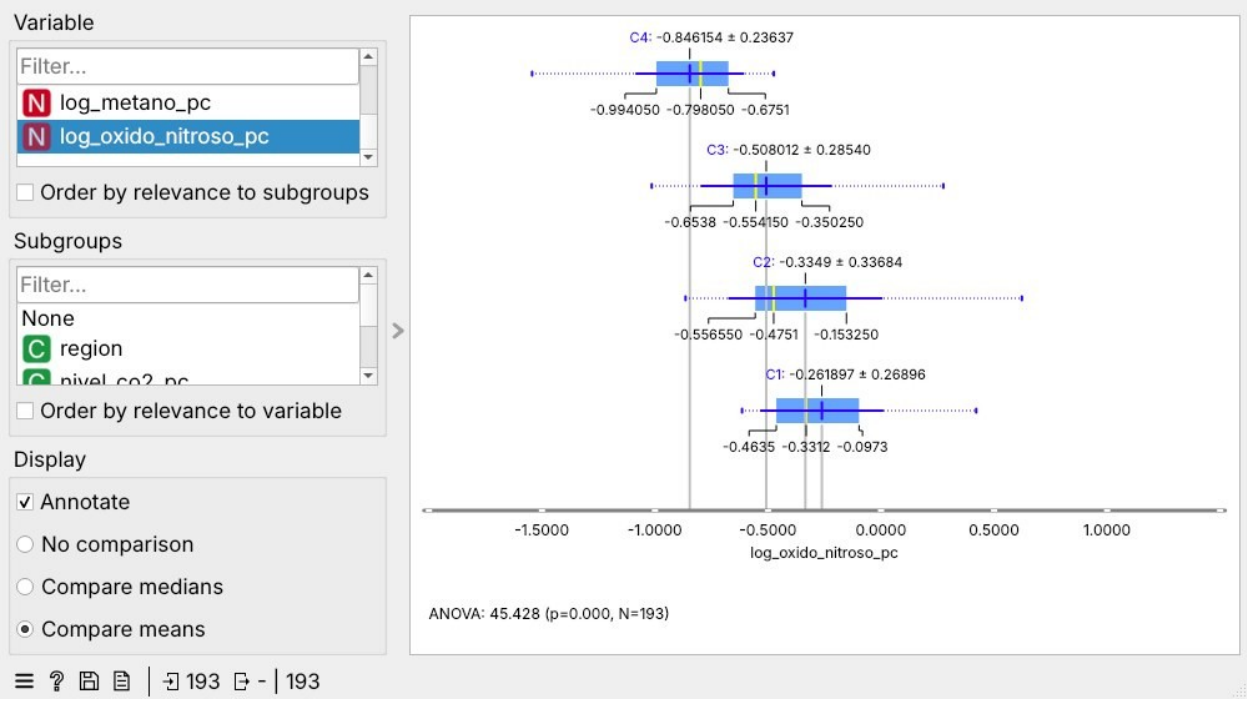
Electricidad per cápita (log10) por grupo



Nota. Captura del flujo en Orange Data Mining.

Figura A5

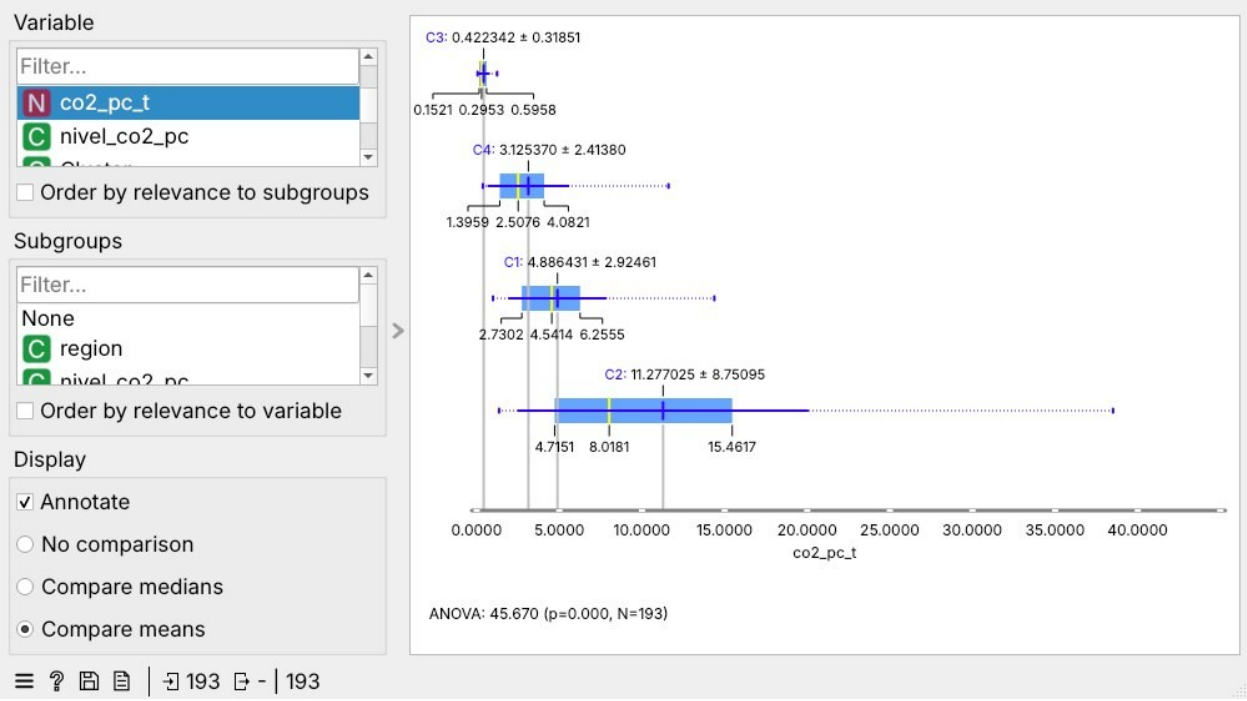
Óxido nitroso per cápita (log10) por grupo



Nota. Captura del flujo en Orange Data Mining.

Figura A6

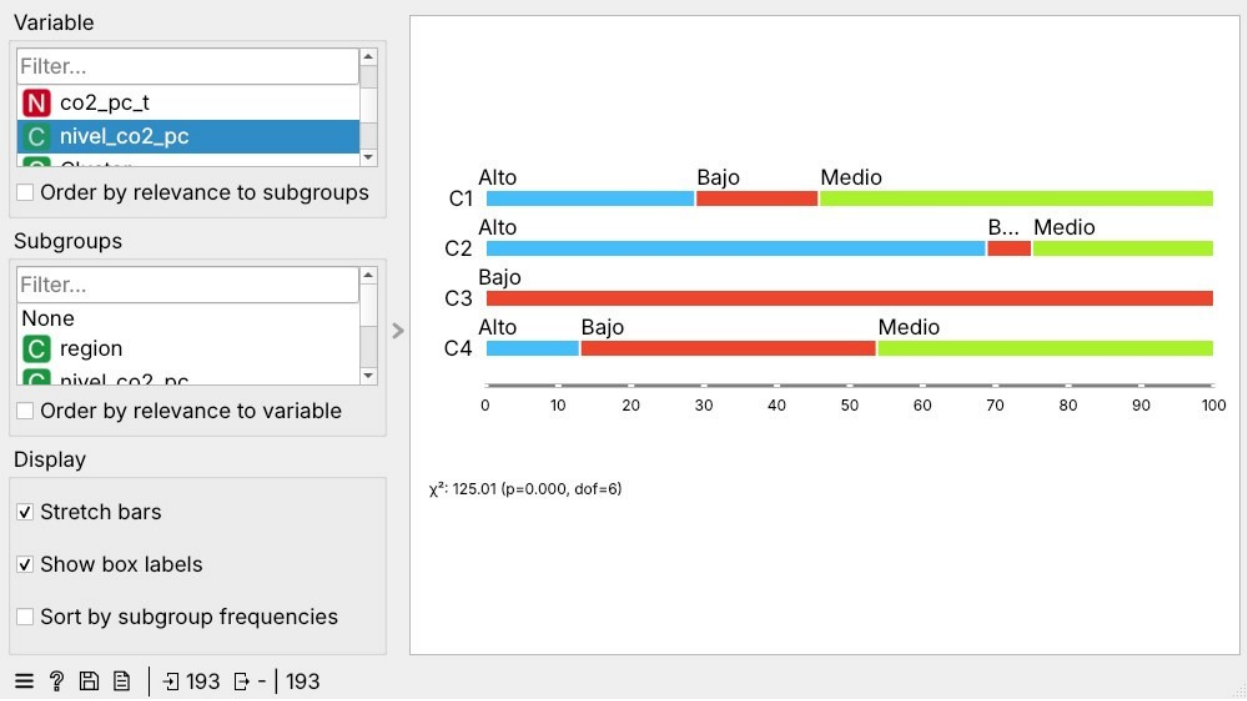
CO2 per cápita por grupo (solo descripción)



Nota. Captura del flujo en Orange Data Mining.

Figura A7

Nivel de CO2 dentro de cada grupo



Nota. Captura del flujo en Orange Data Mining.