Universidad de
CUNDINAMARCA

CLIMATEC

Etapa 6 · Conocimiento oculto

Cambio climático y eventos externos:

modelos supervisados, clustering y análisis de comentarios de YouTube en Orange Data Mining

Global · Sudamérica · Colombia · 2020-2024

Informe técnico
Ana Cortes · Mateo Melgarejo · Andrés Pineda
Minería de Datos · Universidad de Cundinamarca
Gestor del conocimiento: Luz Helena Álvarez
Noviembre de 2026

Contenido y enlaces de entrega

Universidad de CUNDINAMARCA

1. Contexto, objetivo y preguntas de análisis
2. Datos y transformaciones
3. Flujos de Orange: widgets, conexiones y parámetros
4. Aprendizaje supervisado: tres modelos y selección
5. Clustering: k-Means y caracterización de grupos
6. Comentarios de YouTube: API, limpieza y análisis
7. Conclusiones integradas, evidencia e hipótesis
8. Limitaciones y reproducibilidad

Referencias

Tabla 1

Enlaces de acceso a los productos entregados

Producto	Enlace
Repositorio del proyecto	https://github.com/veels3122/ClimaTec
Aplicación Flask publicada	https://climatec-ctrm.onrender.com
Sección «Conocimiento Oculto»	https://climatec-ctrm.onrender.com/etapa-6/contexto-y-preguntas
Video de sustentación	Pendiente: agregar enlace antes de entregar
Flujos de Orange	climate-mining-app/data/etapa6/*.ows

Nota. Los enlaces se verificaron con acceso público. La clave de la API de YouTube no se publica en ningún producto.

1. Contexto y objetivo

Universidad de CUNDINAMARCA

Problema del proyecto. ClimaTec analiza la relación entre las tendencias recientes del cambio climático (emisiones de CO2 y GEI, concentración atmosférica y anomalías de temperatura) y los eventos externos, a escala global, regional (Sudamérica) y nacional (Colombia), entre 2020 y 2026.

De dónde venimos. Las etapas 4 y 5 describieron qué pasa: quién emite más, cómo cambia en el tiempo y cómo se reparte por región (conocimiento evidente y análisis multidimensional OLAP).

Qué agrega esta etapa. Busca el conocimiento que no se ve a simple vista: qué combinación de rasgos explica el nivel de emisión de un país, qué perfiles de países existen más allá de los continentes y qué opina el público.

Objetivo

Descubrir patrones, relaciones y comportamientos que profundicen la comprensión del problema mediante modelos supervisados y de clustering en Orange Data Mining, y complementar los hallazgos con el análisis de comentarios extraídos con la API de YouTube.

Insumos

- Conjunto limpio de las etapas 2 y 3 (clima_limpio.csv, 21.369 observaciones, 24 indicadores, 231 países).
- Región de cada país (dim_pais_region.csv).
- Comentarios públicos de un video de YouTube.

1. Preguntas de análisis

Universidad de CUNDINAMARCA

Tabla 2

Preguntas que guían la Etapa 6

Sección	Pregunta	Técnica en Orange
Supervisado	¿Se puede predecir si un país es emisor Bajo, Medio o Alto de CO2 per cápita a partir de su perfil energético y de sus emisiones de gases distintos al CO2?	Árbol de decisión, Random Forest y regresión logística; Test and Score
Clustering	¿Qué perfiles energético-emisores comparten los países, más allá de su nivel de CO2 per cápita?	k-Means (k = 2...8) con silueta
Comentarios	¿Qué temas, opiniones y sentimientos expresa el público sobre el cambio climático, y coinciden con lo que muestran los datos?	Corpus, Preprocess Text, Bag of Words, LDA, Sentiment Analysis, Hierarchical Clustering

Relación con la pregunta principal. La pregunta principal compara el mundo, Sudamérica y Colombia. El modelo supervisado explica por qué un país emite lo que emite; el clustering ubica a Colombia junto a países con un perfil parecido, no solo junto a sus vecinos; los comentarios agregan la percepción del público, que los datos numéricos no contienen.

2. Datos: unidad de análisis y depuración

Una fila por país. El conjunto limpio está en formato largo (indicador × país × fecha). Se pivotó a una fila por país con el promedio 2020-2024 de cada indicador; 2025 y 2026 casi no tienen datos nacionales.

¿Por qué no país-año? Si el mismo país aparece cinco veces, la validación cruzada pone años del mismo país en entrenamiento y prueba: el modelo «reconoce» al país en lugar de aprender el patrón y las métricas salen infladas.

Script reproducible. scripts/conocimiento_oculto.py genera supervisado_paises.csv y clustering_paises.csv con encabezados que Orange interpreta directamente: cD# objetivo, C# numérica, D# categórica, m# meta.

Tabla 3

Trazabilidad de la depuración

Paso de depuración	Países
Entidades nacionales en el conjunto limpio	231
– Sin CO2 per cápita (sin objetivo)	18
– Con menos de 4 de 6 predictores	9
Archivo supervisado	**204**
Archivo de clustering (sin faltantes)	**193**

Nota. Faltantes que imputa Orange dentro de cada pliegue (promedio): electricidad_pc_kwh (2), intensidad_red_tco2e_mwh (3), metano_pc_tco2e (8), oxido_nitroso_pc_tco2e (8).

2. Variables y prevención de fuga de información

Universidad de CUNDINAMARCA

Tabla 4

Variables derivadas para los modelos

Variable	Cálculo	Uso
energia_pc_kwh	Consumo de energía per cápita (OWID)	Supervisado; clustering (log10)
electricidad_pc_kwh	Generación eléctrica (TWh) × 10^9 / población	Supervisado; clustering (log10)
intensidad_red_tco2e_mwh	GEI del sector eléctrico / generación	Supervisado; clustering
metano_pc_tco2e	Metano × 10^6 / población	Supervisado; clustering (log10)
oxido_nitroso_pc_tco2e	Óxido nitroso × 10^6 / población	Supervisado; clustering (log10)
log_poblacion	log10(población)	Supervisado
region	Continente (dim_pais_region.csv)	Supervisado; descripción
nivel_co2_pc	Bajo < 2 t · Medio 2–6 t · Alto ≥ 6 t	Objetivo; solo descripción en clustering

Sin fuga de información

Se excluyeron todas las variables que contienen el CO2 o se calculan con él, porque no estarían disponibles sin conocer la respuesta:

- Emisiones de CO2 total y por combustible
- CO2 acumulado
- Variación anual de CO2
- Contribución del CO2 y los GEI a la temperatura
- GEI total y per cápita (incluyen el CO2)

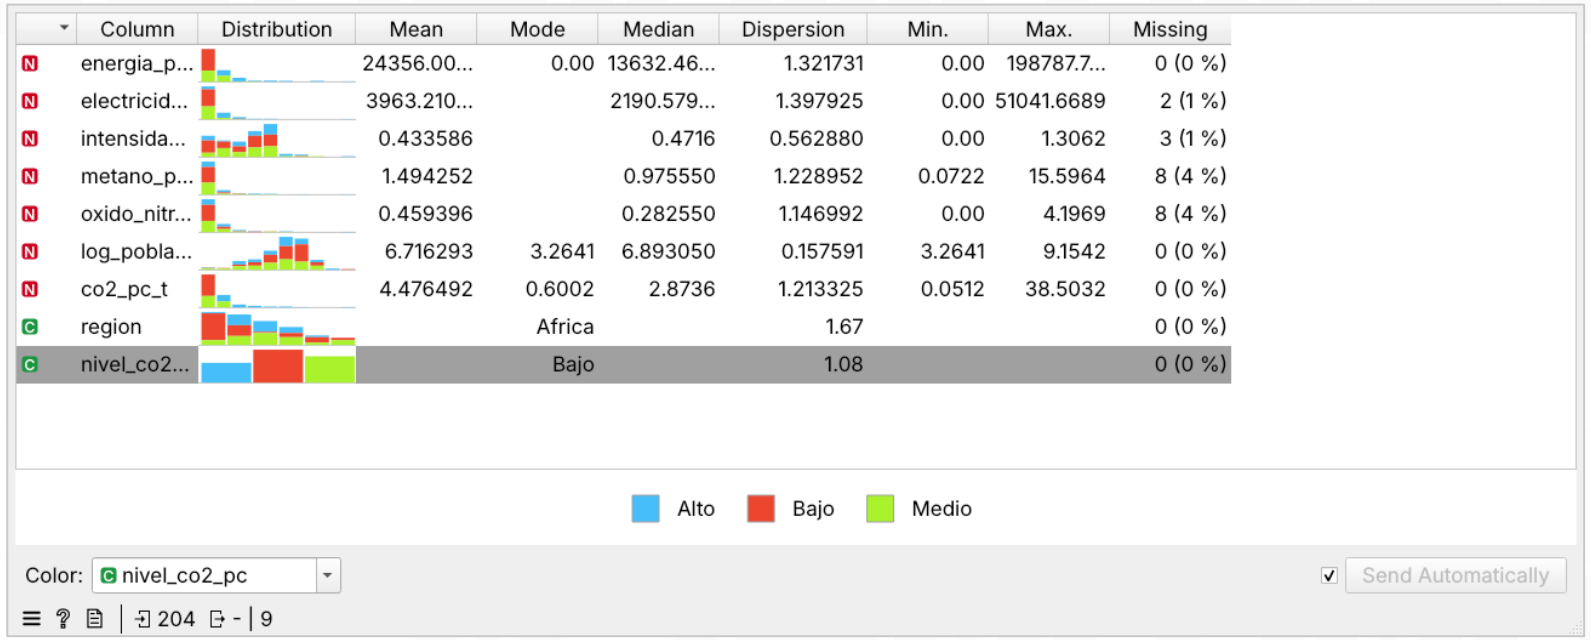
La imputación y la estandarización son preprocesadores del modelo: Orange las ajusta dentro de cada pliegue de la validación cruzada.

2. Distribución de las variables y transformación log10

Universidad de CUNDINAMARCA

Figura 1

Estadísticas de las variables del archivo supervisado (Feature Statistics)



	Column	Distribution	Mean	Mode	Median	Dispersion	Min.	Max.	Missing
N	energia_p...		24356.00...	0.00	13632.46...	1.321731	0.00	198787.7...	0 (0 %)
N	electricid...		3963.210...		2190.579...	1.397925	0.00	51041.6689	2 (1 %)
N	intensida...		0.433586		0.4716	0.562880	0.00	1.3062	3 (1 %)
N	metano_p...		1.494252		0.975550	1.228952	0.0722	15.5964	8 (4 %)
N	oxido_nitr...		0.459396		0.282550	1.146992	0.00	4.1969	8 (4 %)
N	log_pobla...		6.716293	3.2641	6.893050	0.157591	3.2641	9.1542	0 (0 %)
N	co2_pc_t		4.476492	0.6002	2.8736	1.213325	0.0512	38.5032	0 (0 %)
C	region			Africa		1.67			0 (0 %)
C	nivel_co2...			Bajo		1.08			0 (0 %)

Nota. Captura del widget Feature Statistics en Orange. Se observa la cola larga de energía y electricidad per cápita.

Asimetría fuerte. Unos pocos petroestados e islas pequeñas tienen valores diez o cien veces mayores que la mediana (energía per cápita de 199.000 kWh frente a una mediana cercana a 14.000).

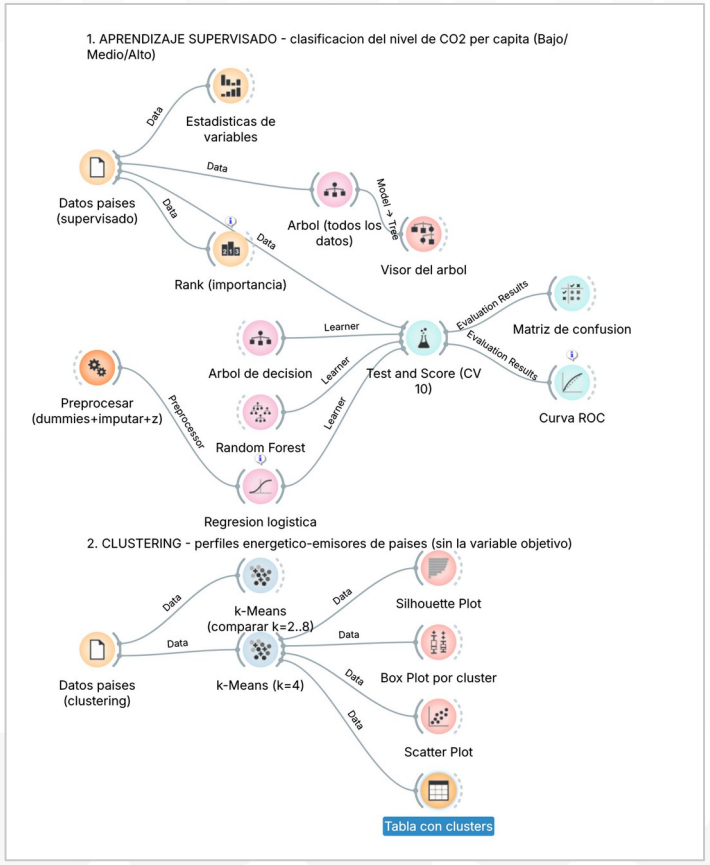
Efecto en k-Means. Sin transformar, k = 2 solo separaba 20 países extremos de los otros 173.

Decisión. Para el clustering se aplicó log10 a energía, electricidad, metano y N_2O, y luego estandarización (Normalize columns). Los árboles no lo necesitan; la regresión logística estandariza en su preprocesador.

3. Flujo de Orange: modelos supervisados y clustering

Figura 2

Flujo etapa6_conocimiento_oculto.ows



Nota. Arriba, aprendizaje supervisado; abajo, clustering.

Supervisado. File carga supervisado_paises.csv y alimenta Feature Statistics, Rank, Test and Score y un árbol entrenado con todos los datos (solo para leer reglas en Tree Viewer). Los tres learners se conectan a Test and Score, que envía sus resultados a Confusion Matrix y ROC Analysis.

Preprocesador. Preprocess (Continuize → Impute → Normalize) entra en la regresión logística. Hallazgo: al conectar un preprocesador, Orange deja de aplicar los pasos por defecto del learner; con solo Normalize el modelo fallaba por la variable categórica region.

Clustering. File carga clustering_paises.csv. Un k-Means compara k = 2...8 y otro fija k = 4; su salida (columna Cluster) va a Silhouette Plot, Box Plot, Scatter Plot y Data Table.

Rutas relativas. Los .ows guardan la ruta relativa a su carpeta: se abren desde data/etapa6/ y encuentran los CSV.

3. Widgets, conexiones y parámetros

Universidad de CUNDINAMARCA

Tabla 5

Configuración del flujo de modelos

Widget	Parámetros	Conexión
File (supervisado)	Objetivo nivel_co2_pc; metas país, ISO3, CO2	Data → Statistics, Rank, Test and Score, Tree
Preprocess	Continuize (una columna por valor), Impute (promedio), Normalize ($\mu = 0$, $\sigma^2 = 1$)	Preprocessor → Logistic Regression
Tree	Binario; hoja ≥ 5; no dividir < 10; profundidad ≤ 5; mayoría 95 %	Learner → Test and Score
Random Forest	100 árboles; semilla fija; no dividir subconjuntos < 5	Learner → Test and Score
Logistic Regression	Ridge (L2), C = 1	Learner → Test and Score
Test and Score	Validación cruzada de 10 pliegues, estratificada	Results → Confusion Matrix, ROC
File (clustering)	5 variables; resto como meta (incluye nivel_co2_pc)	Data → k-Means
k-Means	k = 2...8 y k = 4; Normalize columns; k-means++; 10 reinicios; 300 iteraciones	Data → Silhouette, Box Plot, Scatter, Table

4. Aprendizaje supervisado: planteamiento

Universidad de CUNDINAMARCA

Pregunta de predicción

¿Se puede predecir si un país es emisor Bajo, Medio o Alto de CO2 per cápita a partir de su perfil energético y de sus emisiones de gases distintos al CO2?

Clasificación, no regresión. El CO2 per cápita es continuo, pero va de 0,05 a 38 t por persona: en una regresión unos pocos países dominarían el error. Para el proyecto interesa ubicar a un país en un nivel de emisión, no estimar la décima exacta.

Umbrales. Definidos por el equipo: 2 t como referencia de emisión baja por persona y 6 t, claramente por encima del promedio mundial (≈ 4,7 t).

Predictoras. Cuánta energía usa el país, qué tan limpia es su red eléctrica, cuánto emite de otros gases, su tamaño y su región.

Tabla 6

Distribución de la variable objetivo

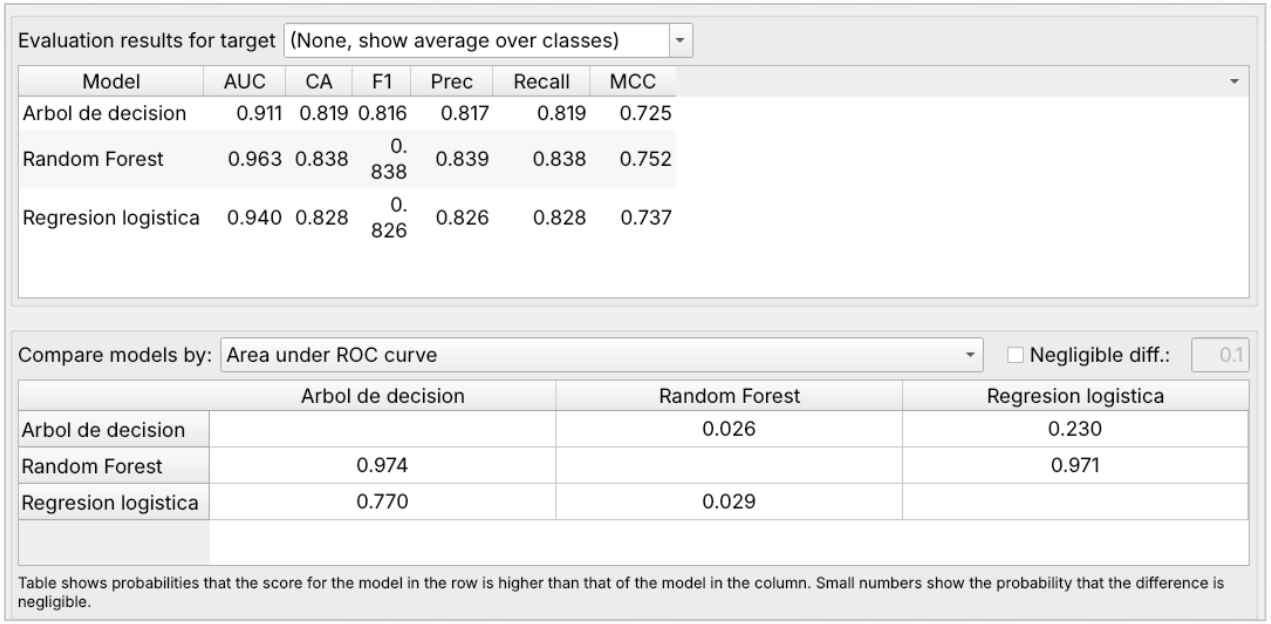
Clase	Países	%
Bajo	85	41,7
Medio	68	33,3
Alto	51	25,0
Total	204	100

Desbalance moderado. Se usa validación estratificada (cada pliegue conserva las proporciones) y se reportan métricas ponderadas y por clase. Un modelo que siempre dijera «Bajo» acertaría el 41,7 %: es la línea base a superar.

4. Evaluación de los tres modelos

Figura 3

Resultados del widget Test and Score



Evaluation results for target (None, show average over classes)

Model	AUC	CA	F1	Prec	Recall	MCC
Arbol de decision	0.911	0.819	0.816	0.817	0.819	0.725
Random Forest	0.963	0.838	0.838	0.839	0.838	0.752
Regresion logistica	0.940	0.828	0.826	0.826	0.828	0.737

Compare models by: Area under ROC curve — Negligible diff.: 0.1

	Arbol de decision	Random Forest	Regresion logistica
Arbol de decision		0.026	0.230
Random Forest	0.974		0.971
Regresion logistica	0.770	0.029	

Table shows probabilities that the score for the model in the row is higher than that of the model in the column. Small numbers show the probability that the difference is negligible.

Nota. Validación cruzada de 10 pliegues estratificada; promedio sobre las clases.

Tabla 7

Métricas (ponderadas)

Modelo	AUC	CA	F1	Prec.	Recall	MCC
Arbol de decision	0,911	0,819	0,816	0,817	0,819	0,725
Random Forest	**0,963**	**0,838**	**0,838**	**0,839**	**0,838**	**0,752**
Regresion logistica	0,940	0,828	0,826	0,826	0,828	0,737

- Los tres superan ampliamente la línea base (41,7 %).
- Random Forest es el mejor en todas las métricas.
- Comparación bayesiana de AUC (parte inferior de la figura): Random Forest supera al árbol con probabilidad 0,974 y a la regresión logística con 0,971.
- MCC (−1 a 1) resume la matriz completa y es robusto al desbalance.

4. Matrices de confusión y errores

Figura 4

Matriz de confusión: Árbol de decisión

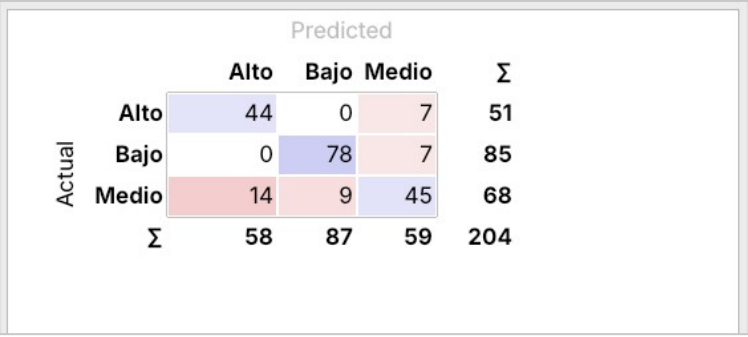


Figura 5

Matriz de confusión: Random Forest

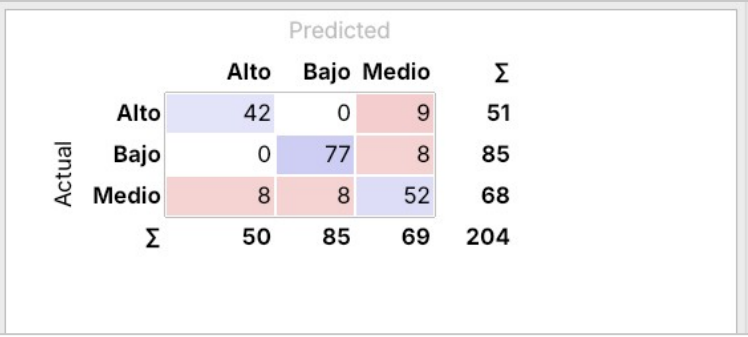


Figura 6

Matriz de confusión: Regresión logística

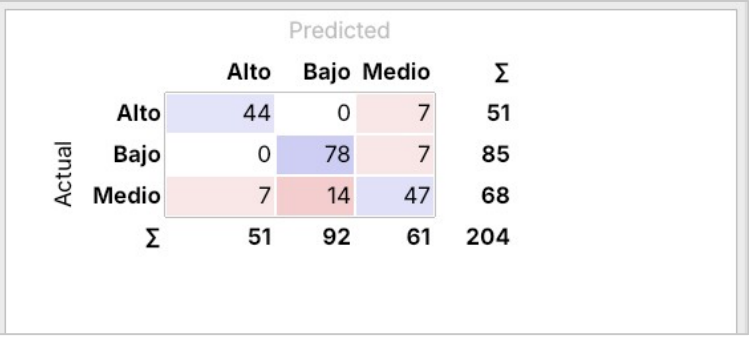


Tabla 8

Precisión (P), recall (R) y F1 por clase

Clase	Árbol P	Árbol R	Árbol F1	RF P	RF R	RF F1	Logística P	Logística R	Logística F1
Bajo	0,90	0,92	0,91	0,91	0,91	0,91	0,85	0,92	0,88
Medio	0,76	0,66	0,71	0,75	0,77	0,76	0,77	0,69	0,73
Alto	0,76	0,86	0,81	0,84	0,82	0,83	0,86	0,86	0,86

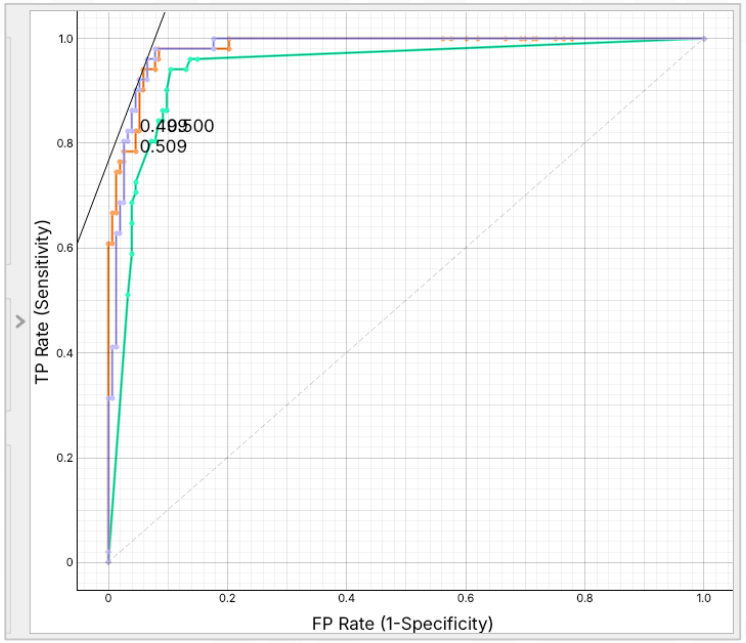
Lectura. Ningún modelo confunde Bajo con Alto: todos los errores involucran la clase Medio, frontera entre las otras dos. El árbol llama «Alto» a 14 países Medios; la logística los llama «Bajo» (14); Random Forest reparte sus errores (8 y 8) y es el que más Medios acierta (52 de 68).

4. Curva ROC e importancia de las variables

Universidad de CUNDINAMARCA

Figura 7

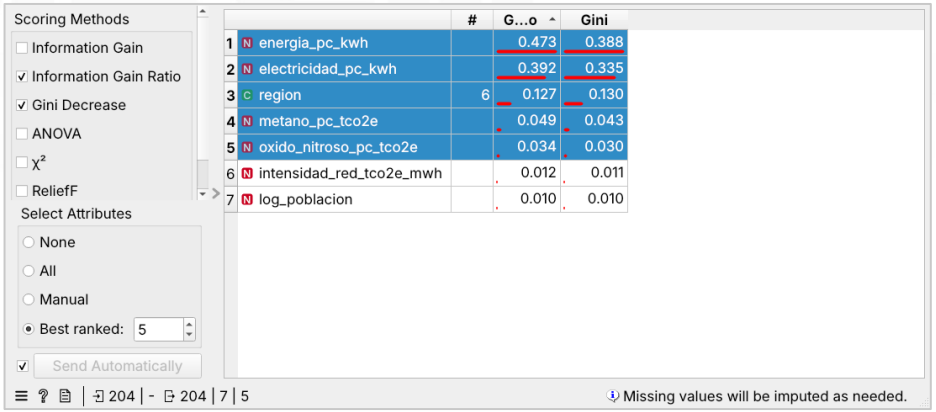
Curva ROC para la clase Alto



Nota. Las tres curvas quedan muy por encima de la diagonal.

Figura 8

Importancia de las predictoras (Rank)



		#	G...o	Gini
1	energia_pc_kwh		0.473	0.388
2	electricidad_pc_kwh		0.392	0.335
3	region	6	0.127	0.130
4	metano_pc_tco2e		0.049	0.043
5	oxido_nitroso_pc_tco2e		0.034	0.030
6	intensidad_red_tco2e_mwh		0.012	0.011
7	log_poblacion		0.010	0.010

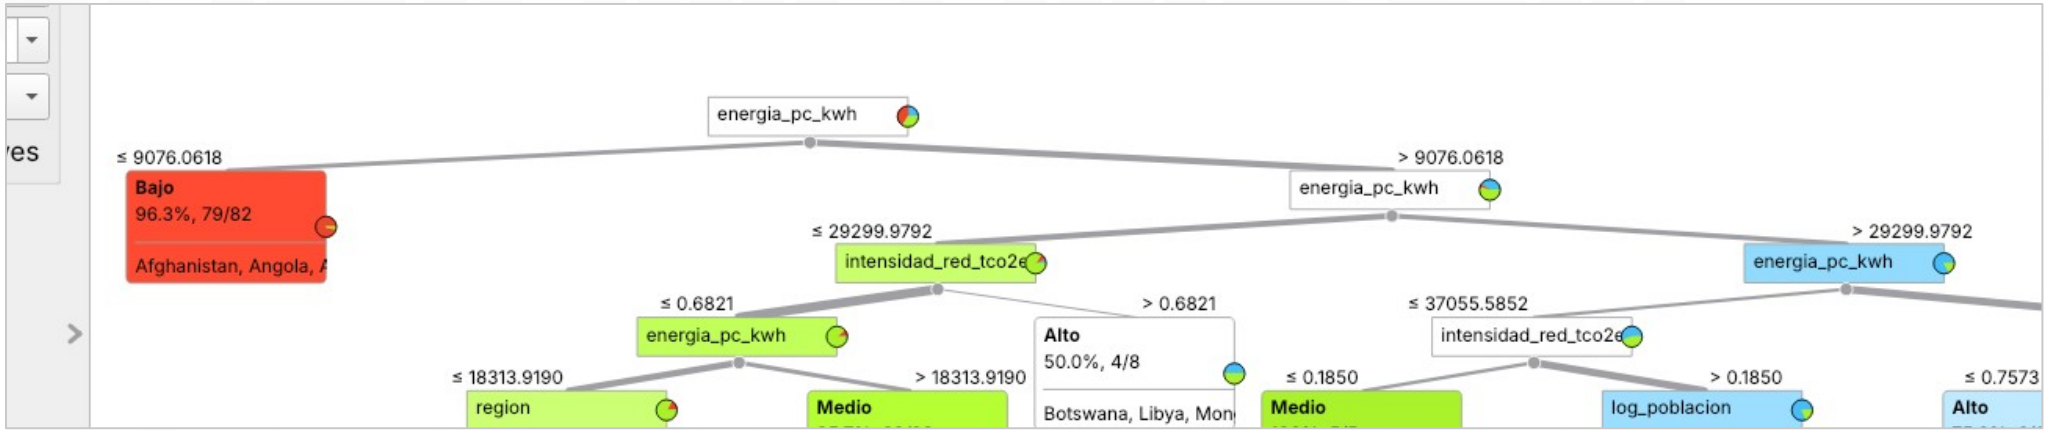
Nota. Ganancia de información, razón de ganancia y Gini.

Energía y electricidad per cápita son, con diferencia, las más informativas (ganancia 0,946 y 0,784); en Random Forest suman el 67 % de la importancia. La intensidad de la red casi no informa sola (0,024), pero el árbol la usa después de la energía para separar Medio de Alto.

4. Reglas del árbol de decisión

Figura 9

Árbol de decisión entrenado con todos los datos (Tree Viewer)



Nota. Se usa solo para interpretar; las métricas provienen de la validación cruzada.

- Energía ≤ 9.076 kWh por persona → Bajo (79 de 82 países, 96 %)
- Energía entre 9.076 y 29.300 kWh e intensidad de la red ≤ 0,68 t/MWh → Medio (51 de 58)
- Energía > 37.056 kWh y metano > 0,76 t por persona → Alto (27 de 27, 100 %)
- Energía entre 29.300 y 37.056 kWh con red muy limpia (≤ 0,185 t/MWh) → Medio (Suiza, Dinamarca…)

Caso Colombia

1,8 t por persona (Bajo), 11.362 kWh por persona y red de 0,25 t/MWh. El árbol la ubica en Medio: está a 0,2 t del umbral y su red hidroeléctrica es lo que la mantiene abajo.

4. Modelo seleccionado: Random Forest

Universidad de CUNDINAMARCA

Justificación

- Mejor en todas las métricas: AUC 0,963; F1 0,838; MCC 0,752.
- Diferencia creíble: 97 % de probabilidad de superar a los otros dos en AUC.
- Mejor manejo de la clase difícil (Medio: F1 0,76).
- No exige estandarizar ni linealidad y tolera valores extremos.

Conocimiento que aporta

El nivel de emisión de un país se explica sobre todo por cuánta energía usa y, en segundo lugar, por cómo la produce (red eléctrica) y por el metano. Esto va más allá de las etapas descriptivas, que mostraban el nivel pero no qué lo explica.

Limitaciones

- Menos interpretable que el árbol: por eso el árbol se mantiene como apoyo para explicar reglas.
- 204 países: cada pliegue evalúa unos 20, así que las métricas tienen una incertidumbre de algunos puntos.
- Muestra asociación, no causalidad; usa promedios 2020-2024, que incluyen el año atípico de la pandemia; los umbrales de clase son una decisión del equipo.

5. Clustering: planteamiento y elección de k

Pregunta. ¿Qué perfiles energético-emisores comparten los países, más allá de su nivel de CO2 per cápita?

Variables. log10 de energía, electricidad, metano y N_2O per cápita, e intensidad de la red. No se usan el CO2, el nivel de emisión (objetivo del supervisado, queda como meta) ni la región, para ver si los perfiles cruzan continentes.

Algoritmo. k-Means con k-means++, 10 reinicios, 300 iteraciones y estandarización. Se compararon k = 2 a 8 con la silueta (de −1 a 1; más alto indica grupos compactos y separados).

Elección: k = 4. k = 2 y k = 4 tienen casi la misma silueta (0,287 y 0,285). k = 2 solo divide «mucha o poca energía»; k = 4 distingue además la limpieza de la red y el metano, que es lo que interesa al proyecto.

Figura 10

Silueta por k en k-Means

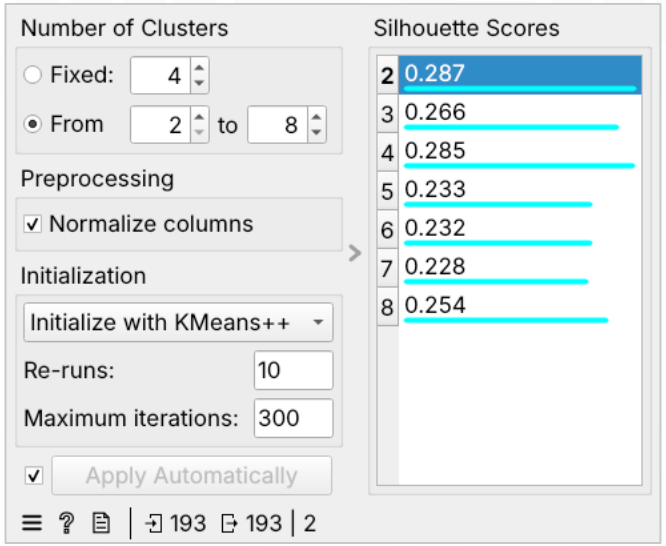


Tabla 9

Comparación de k

k	Silueta
2	0,287
3	0,266
4	**0,285**
5	0,233
6	0,232
7	0,228
8	0,254

Nota. Una silueta cercana a 0,3 indica estructura real pero con fronteras difusas entre grupos (Rousseeuw, 1987).

5. Caracterización de los grupos

Universidad de CUNDINAMARCA

Tabla 10

Medianas por grupo (k = 4)

Grupo	n	Energía kWh/p	Electr. kWh/p	Red t/MWh	Metano t/p	N_2O t/p	Var. CO2 %/año	CO2 t/p	Silueta
C1	59	25.570	4.505	0,19	1,14	0,47	-1,6	4,5	0,25
C2	32	31.007	4.940	0,66	3,22	0,34	+1,1	8,0	0,02
C3	48	1.359	155	0,36	0,93	0,28	+2,9	0,3	0,37
C4	54	10.664	1.713	0,60	0,56	0,16	+1,0	2,5	0,19

Nota. CO2 y su variación no se usaron para agrupar; se muestran para describir. Silueta por grupo tomada del Silhouette Plot.

Figura 11

Silhouette Plot (k = 4)

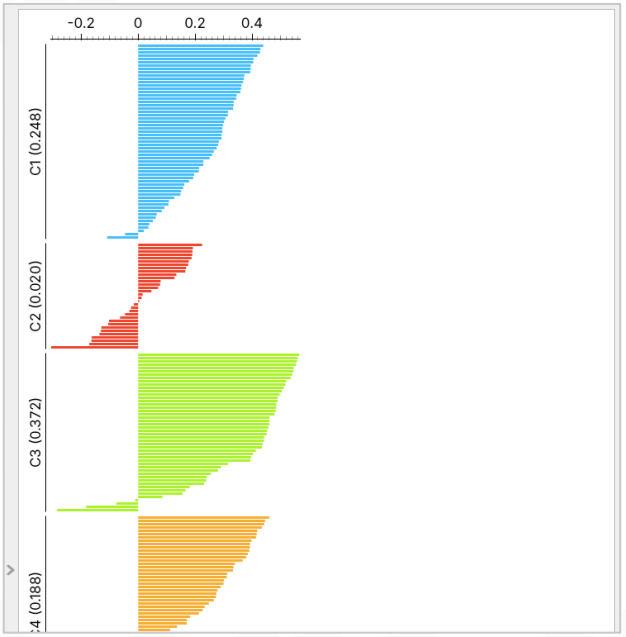


Tabla 11

Nivel de CO2 por grupo

Grupo	Bajo	Medio	Alto
C1	10	32	17
C2	2	8	22
C3	48	0	0
C4	22	25	7

Lectura. C3 es 100 % Bajo y C2 concentra los Altos, pero C1 y C4 mezclan los tres niveles: el mismo nivel de emisión se alcanza con perfiles distintos.

5. Descripción de los cuatro perfiles

Universidad de CUNDINAMARCA

C1 · 59 países · Red eléctrica limpia y emisiones a la baja

Consumo de energía alto o medio con la red eléctrica menos intensiva en carbono (hidroeléctrica o nuclear). Es el único grupo cuyas emisiones de CO_2 bajan en el periodo.

Regiones: Europa 32, Sudamérica 10, Asia 8, Norteamérica 6

Ejemplos: Slovakia, France, Hungary, Croatia, Spain

Para decidir: Referente de desacople: se puede consumir energía sin emitir al ritmo de los fósiles. Colombia está aquí; el reto es proteger la generación hídrica frente a sequías como las de El Niño 2023-2024.

C2 · 32 países · Productores de hidrocarburos intensivos en carbono

El consumo de energía más alto, la red más sucia y el metano per cápita más alto (extracción de petróleo y gas). Concentra la mayoría de los emisores Altos.

Regiones: Asia 19, África 5, Europa 4, Sudamérica 2

Ejemplos: Kazakhstan, Libya, Brunei, Saudi Arabia, Turkmenistan

Para decidir: Prioridad para políticas de metano (fugas y quema en antorcha) y para descarbonizar la red: pequeños cambios en estos países mueven mucho las emisiones por persona.

C3 · 48 países · Baja energía y baja electrificación

Consumo de energía y electricidad muy bajos; todos son emisores Bajos. Sin embargo, es el grupo cuyas emisiones crecen más rápido.

Regiones: África 36, Asia 7, Norteamérica 4, Oceanía 1

Ejemplos: Tanzania, Uganda, Madagascar, Ethiopia, Burkina Faso

Para decidir: Oportunidad para crecer con renovables desde el inicio: su emisión es baja hoy, pero la tendencia es al alza.

C4 · 54 países · Transición intermedia dependiente de fósiles

Consumo de energía intermedio con red eléctrica intensiva en carbono (diésel, carbón o gas) y poco metano y óxido nitroso. Incluye muchas islas pequeñas e India.

Regiones: Asia 16, Norteamérica 15, África 13, Oceanía 7

Ejemplos: Saint Lucia, Grenada, Maldives, Saint Vincent and the Grenadines, Mauritius

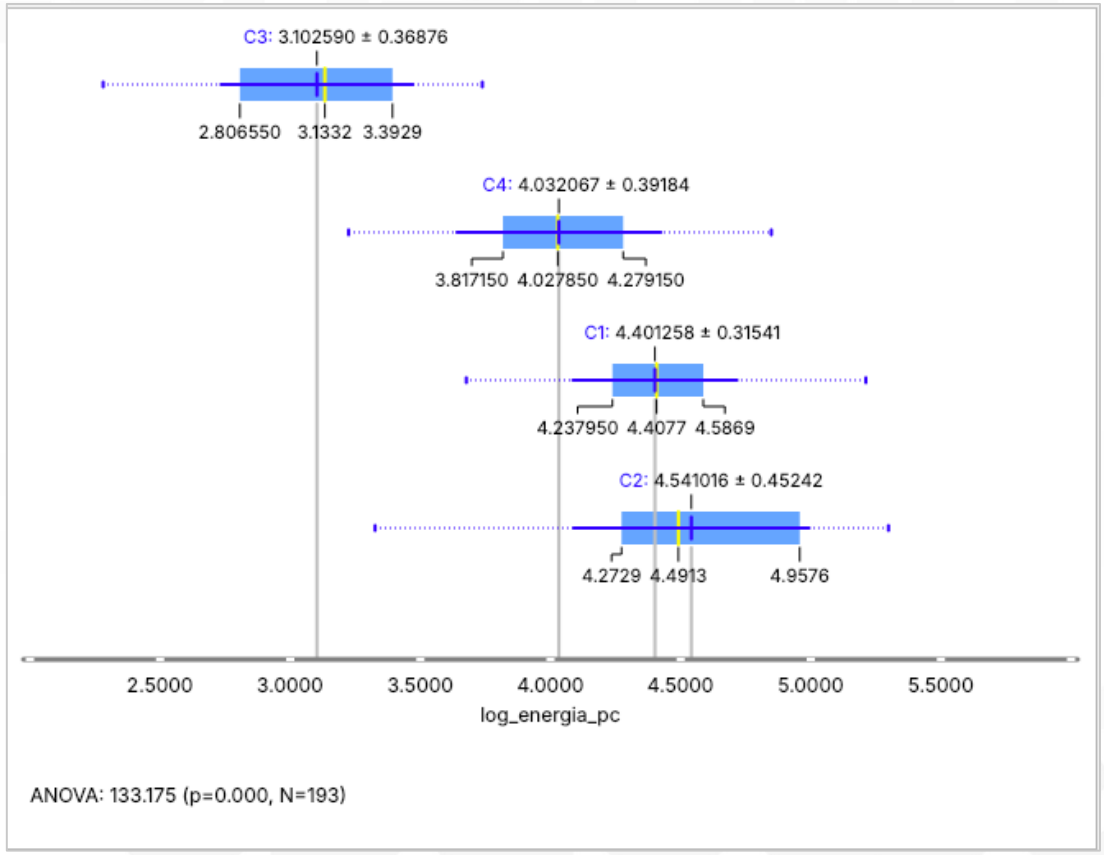
Para decidir: La palanca es la red eléctrica: reemplazar generación fósil por renovable reduce emisiones sin frenar el consumo.

5. Evidencia visual de los grupos (1/2)

Universidad de CUNDINAMARCA

Figura 12

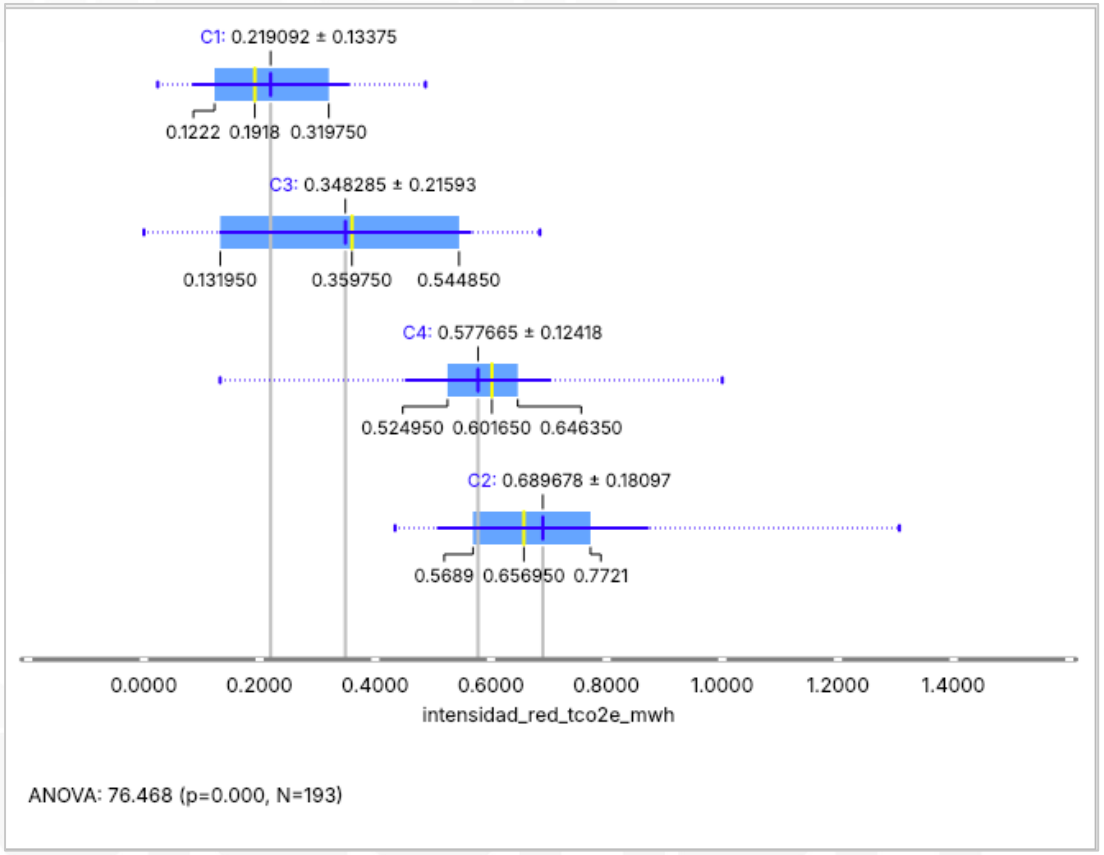
Energía per cápita (log10) por grupo (Box Plot)



Nota. ANOVA F = 133; p < 0,001. C3 consume diez veces menos que los demás.

Figura 13

Intensidad de la red eléctrica por grupo (Box Plot)



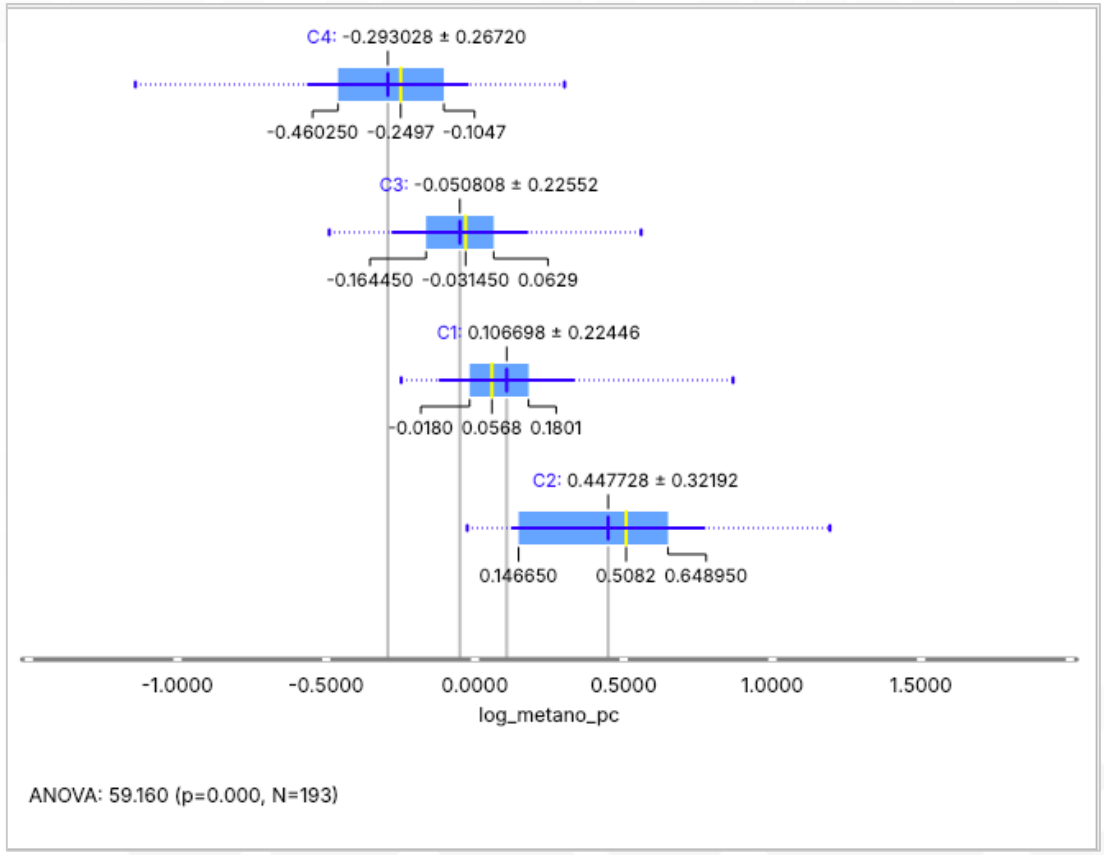
Nota. ANOVA F = 76; p < 0,001. C1 tiene la red más limpia; C2 y C4 las más sucias.

5. Evidencia visual de los grupos (2/2)

Universidad de CUNDINAMARCA

Figura 14

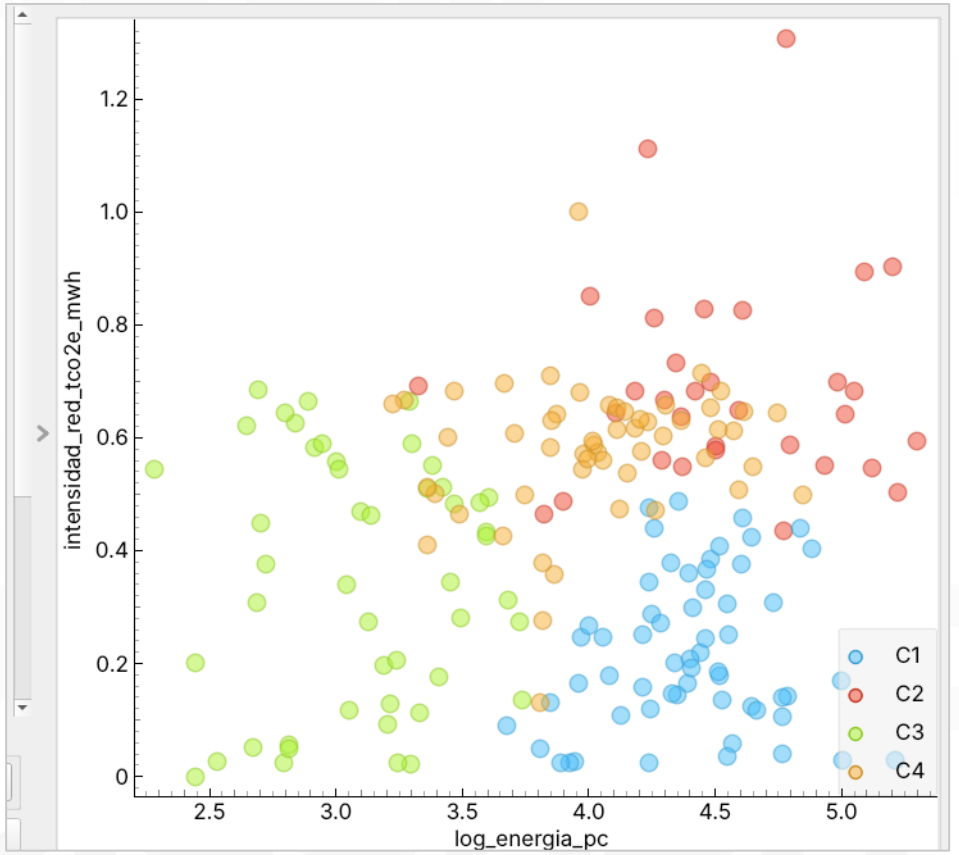
Metano per cápita (log10) por grupo (Box Plot)



Nota. ANOVA F = 59; p < 0,001. C2 se separa del resto.

Figura 15

Energía per cápita (x) frente a intensidad de la red (y), coloreado por grupo

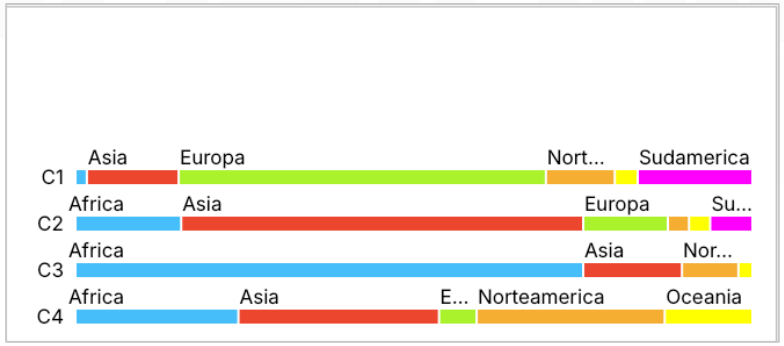


Nota. C1 (azul) y C4 (naranja) consumen parecido; los separa la red.

5. Patrones ocultos que revela el clustering

Figura 16

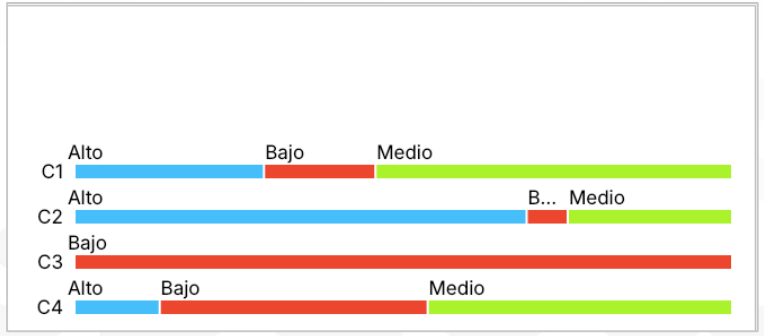
Región dentro de cada grupo



Nota. La región no se usó para agrupar.

Figura 17

Nivel de CO2 dentro de cada grupo



Nota. El nivel tampoco se usó para agrupar.

1. Igual nivel, trayectorias opuestas. C1 y C4 tienen países Medios y Altos, pero C1 llega ahí con red limpia y emisiones que bajan (−1,6 %/año) y C4 con red sucia y emisiones que suben (+1,0 %/año).

2. Sudamérica se parece a Europa. 10 de 12 países sudamericanos, Colombia incluida, caen en C1 por su generación hidroeléctrica.

3. Los que menos emiten crecen más rápido. C3 es 100 % Bajo, pero su CO2 crece +2,9 %/año.

4. El metano identifica a los productores de hidrocarburos (C2) mejor que el consumo, y cruza continentes.

Limitaciones: silueta moderada, sensibilidad a la elección de variables y a la transformación log, y 11 países excluidos por datos faltantes.

6. Comentarios de YouTube: propósito y extracción

Universidad de CUNDINAMARCA

Propósito. Contrastar los hallazgos de los modelos (energía, red eléctrica, metano, diferencias entre países) con la percepción del público hispanohablante: ¿se reconoce el problema?, ¿se asocia a la energía?, ¿hay escepticismo?, ¿aparecen Colombia o eventos externos como El Niño?

Video. Video 0rzAluuejUw · https://www.youtube.com/watch?v=0rzAluuejUw

Criterios. Video en español sobre cambio climático con volumen suficiente de comentarios; comentarios principales (sin respuestas), ordenados por fecha, hasta 500.

Extracción. Fecha y cantidad: se registran en data/etapa6/video_metadatos.json al ejecutar el script.

Procedimiento de conexión a la API

1. Proyecto en Google Cloud Console con YouTube Data API v3 habilitada y clave de API.
2. Clave guardada como Secret de Colab o variable YOUTUBE_API_KEY: nunca en el código ni en el repositorio.
3. scripts/youtube_extraccion.py llama a videos (metadatos) y commentThreads (100 por página, paginando con nextPageToken).
4. Solo se guardan texto, fecha, likes y número de respuestas; no se guardan datos de los autores.

Restricciones encontradas

Cuota diaria de 10.000 unidades; máximo 100 comentarios por página; solo comentarios públicos; los retenidos por moderación no se descargan; las respuestas requieren otra llamada y no se incluyeron.

6. Preparación de los comentarios y flujo de texto

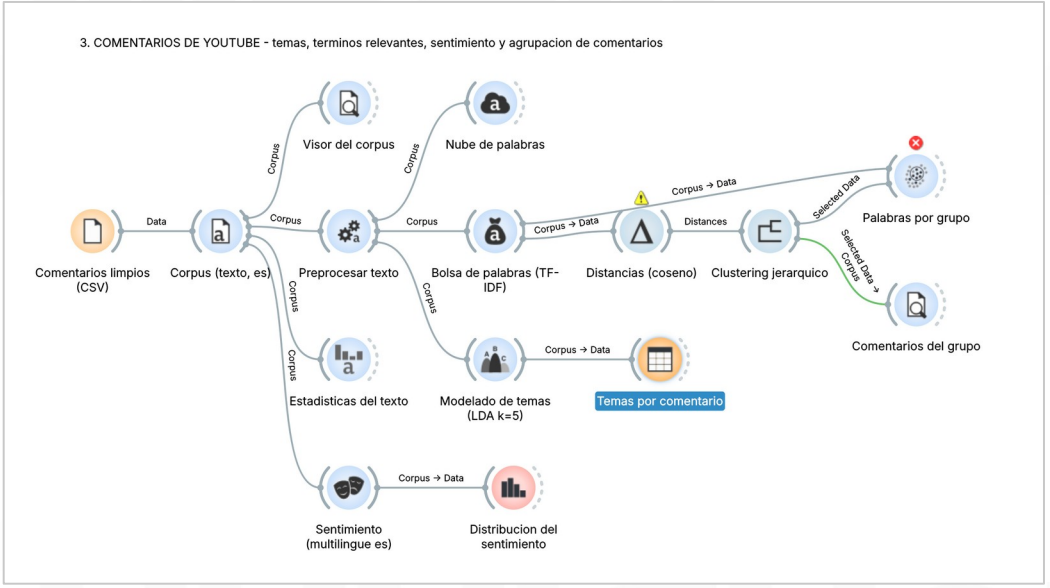
Universidad de CUNDINAMARCA

Reglas de limpieza (scripts/youtube_limpieza.py):

- Vacíos y duplicados exactos (texto normalizado).
- Sin palabras (solo emojis, enlaces o menciones) o con menos de 3 palabras.
- Spam con enlaces y palabras de promoción.
- Se eliminan URL y menciones; no se corrige la ortografía.
- Idioma: detección por palabras vacías; se conserva el español, idioma de las stopwords y del sentimiento.

Figura 18

Flujo etapa6_comentarios_youtube.ows



Widget	Parámetros
Preprocess Text	Minúsculas, sin URL; tokens por regex; stopwords (es), números, signos, tokens de 1-2 letras; frecuencia documental ≥ 3
Bag of Words	TF × IDF, normalización L2
Topic Modelling	LDA, 5 temas
Sentiment Analysis	Multilingual, español
Distances → Hierarchical	Coseno; enlace promedio; Top N = 4; Word Enrichment por grupo

6. Hallazgos de los comentarios

Universidad de CUNDINAMARCA

Sección por completar con la extracción

El flujo de texto ya está construido y probado. Al cargar comentarios_youtube_limpio.csv, esta diapositiva se regenera con: temas LDA y sus términos, palabras más relevantes (TF-IDF), distribución del sentimiento, grupos de comentarios con sus palabras características y ejemplos anónimos.

Alcance. Las opiniones corresponden a quienes comentaron el video seleccionado: no representan a la población de ningún país ni a toda la audiencia. Sirven para generar hipótesis y contrastar percepciones, no para medir opinión pública.

7. Conclusiones integradas: nuevo conocimiento

Universidad de CUNDINAMARCA

1. La energía explica el nivel; la red explica la diferencia

El consumo de energía per cápita separa a los emisores Bajos (96 % en la primera regla del árbol). Entre países con consumo parecido, la red eléctrica decide si son Medios o Altos. Supervisado y clustering coinciden por caminos distintos.

2. Colombia emite poco por su red, no por consumir poco

Consume más que el umbral de los países Bajos, pero su red hidroeléctrica (0,25 t/MWh) la mantiene en 1,8 t por persona. El clustering la ubica con Europa y el resto de Sudamérica.

3. Igual nivel, trayectorias opuestas

Los países Medios de C1 reducen emisiones y los de C4 las aumentan: el nivel actual no dice hacia dónde va un país; el perfil sí.

4. El crecimiento está en los que menos emiten

El grupo de baja energía (C3) es 100 % Bajo pero crece +2,9 % al año. La trayectoria futura depende de cómo se electrifiquen esos países.

Comentarios de YouTube. Su contraste con estos hallazgos (coincidencias, diferencias y temas nuevos) se incorpora al completar la extracción.

7. Evidencia, hipótesis y decisiones

Universidad de CUNDINAMARCA

Respaldado por evidencia

- Energía y electricidad per cápita son las variables más asociadas al nivel de CO2 (Rank, Random Forest y árbol).
- El modelo clasifica bien el 84 % de los países en validación cruzada.
- Los cuatro perfiles difieren de forma significativa (ANOVA $p < 0{,}001$).
- 10 de 12 países sudamericanos comparten el perfil de red limpia.

Hipótesis por validar

- Que mejorar la red reduzca el CO2: el modelo muestra asociación, no causa.
- Que el crecimiento de C3 continúe: solo 5 años, uno de pandemia.
- Que la percepción del público coincida con los datos: los comentarios no son representativos.
- La relación con eventos externos (El Niño, COP) no se modeló directamente.

Decisiones que se pueden apoyar

- Comparar a Colombia con países de su perfil (C1), no solo con sus vecinos.
- Proteger y diversificar la generación renovable: es lo que mantiene a Colombia en nivel Bajo, y El Niño 2023-2024 mostró su vulnerabilidad.
- Seguir el metano en los productores de hidrocarburos (C2).
- Vigilar la tendencia, no solo el nivel.

8. Limitaciones y reproducibilidad

Universidad de CUNDINAMARCA

Limitaciones

- Pocos casos (204 y 193 países) frente a la variedad entre ellos.
- Promedios 2020-2024 que incluyen el año atípico de la pandemia.
- Umbrales de clase definidos por el equipo.
- Silueta moderada en el clustering.
- Un solo proveedor terciario para los indicadores (OWID).
- Comentarios de un único video, en español, de quienes decidieron comentar.

Cómo reproducir el trabajo

1. python scripts/conocimiento_oculto.py → genera los CSV de data/etapa6/.
2. Abrir data/etapa6/etapa6_conocimiento_oculto.ows en Orange 3.36 o superior.
3. Definir YOUTUBE_API_KEY y ejecutar python scripts/youtube_extraccion.py 0rzAluuejUw 500.
4. python scripts/youtube_limpieza.py → comentarios_youtube_limpio.csv.
5. Abrir etapa6_comentarios_youtube.ows (requiere el complemento Text).
6. La sección «Conocimiento Oculto» de la app Flask lee data/etapa6/*.json.

Referencias

Arthur, D., & Vassilvitskii, S. (2007). k-means++: The advantages of careful seeding. En *Proceedings of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms* (pp. 1027–1035). SIAM.

Benavoli, A., Corani, G., Demšar, J., & Zaffalon, M. (2017). Time for a change: A tutorial for comparing multiple classifiers through Bayesian analysis. *Journal of Machine Learning Research, 18*(77), 1–36.

Blei, D. M., Ng, A. Y., & Jordan, M. I. (2003). Latent Dirichlet allocation. *Journal of Machine Learning Research, 3*, 993–1022.

Breiman, L. (2001). Random forests. *Machine Learning, 45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Chicco, D., & Jurman, G. (2020). The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation. *BMC Genomics, 21*, Artículo 6. https://doi.org/10.1186/s12864-019-6413-7

Demšar, J., Curk, T., Erjavec, A., Gorup, Č., Hočevar, T., Milutinovič, M., Možina, M., Polajnar, M., Toplak, M., Starič, A., Štajdohar, M., Umek, L., Žagar, L., Žbontar, J., Žitnik, M., & Zupan, B. (2013). Orange: Data mining toolbox in Python. *Journal of Machine Learning Research, 14*, 2349–2353.

Google. (s. f.). *YouTube Data API: CommentThreads*. Google for Developers. https://developers.google.com/youtube/v3/docs/commentThreads

Han, J., Kamber, M., & Pei, J. (2012). *Data mining: Concepts and techniques* (3.ª ed.). Morgan Kaufmann.

Ritchie, H., Rosado, P., & Roser, M. (2023). *CO_2 and greenhouse gas emissions*. Our World in Data. https://ourworldindata.org/co2-and-greenhouse-gas-emissions

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics, 20*, 53–65. https://doi.org/10.1016/0377-0427(87)90125-7

Universidad de
CUNDINAMARCA

Gracias

ClimaTec · Etapa 6 · Conocimiento oculto

Repositorio: https://github.com/veels3122/ClimaTec
Aplicación: https://climatec-ctrm.onrender.com
Video: pendiente